

涉密论文 ☐ 公开论文 ☒

浙 江 大 学

本科生毕业设计



题目

大模型驱动的高考志愿

推荐系统设计与实现

姓名与学号

潘臻琦 3210102495

指导教师

胡天磊

年级与专业

2021级计算机科学与技术

所在学院

计算机学院

递交日期

2026 年 5 月 18 日

毕业论文（设计）原创性声明

本人郑重声明：所呈交的毕业论文（设计）是本人在导师的指导下，严格按照学校和学院有关规定完成的，不存在学术不端行为。除文中特别加以标注和致谢的地方外，本论文（设计）不包含其他个人或集体已经发表或撰写过的研究成果，也不包含为获得浙江大学或其他教育机构的学位或证书而使用过的材料。对本研究做出贡献的个人和集体，均已在文中明确说明并表示谢意。

毕业论文（设计）作者签名：

签字日期： 年 月 日

毕业论文（设计）使用授权书

本人完全了解浙江大学有权保留并向国家有关部门或机构送交本论文（设计）的复印件和电子版，允许本论文（设计）被查阅和借阅。本人授权浙江大学可以将本论文（设计）的全部或部分内容编入有关数据库进行检索和传播，可以采用影印、缩印或扫描等复制手段保存、汇编本论文（设计）。

（涉密毕业论文（设计）在解密后适用本授权书。）

毕业论文（设计）作者签名：

导师签名：

签字日期： 年 月 日

签字日期： 年 月 日

致谢

本毕业设计从选题、系统实现到论文写作，得到了许多老师、同学和家人的帮助。首先，衷心感谢导师胡天磊老师和合作导师王皓波老师在研究方向、论文结构和工程实现上的指导。老师在问题定义、实验设计和论文表达方面提出了许多宝贵建议，使我能够不断校准研究重点，从一个面向高考志愿填报的工程系统，逐步推进到围绕高风险决策场景中交互式偏好启发与证据驱动谈判的完整研究。

感谢浙江大学计算机学院在本科阶段提供的课程训练和科研环境。数据库系统、机器学习、自然语言处理、软件工程等课程为本设计中的数据治理、智能体架构、检索与评测方法奠定了基础。感谢同学们在实验复现、论文阅读和答辩准备过程中给予的讨论与帮助，这些交流让我能够从不同角度审视系统边界和论文表述。

最后，感谢家人在学习和毕业设计期间给予的理解与支持。毕业设计的完成既是本科阶段学习成果的总结，也是一段持续发现问题、修正问题并形成研究表达的过程。谨以此文向所有给予我帮助和鼓励的人表示诚挚感谢。

摘要

本文围绕大模型驱动的高考志愿推荐系统展开设计与实现。高考志愿填报是一类高风险、多目标、强事实约束的教育决策任务，用户的首轮表达往往带有防御性、试探性和不完整性，并不等同于稳定的真实偏好。传统 Tool AI 或检索增强生成系统通常先接受用户说法，再检索事实并生成建议，适合回答已明确的问题，却容易在隐藏底线场景中把表层愿望误当成完整目标。本文系统将推荐过程改写为证据驱动的混合倡议偏好引出：系统不再被动服从第一轮表述，而是用真实招生证据组织可比较的权衡问题，在多层交互中主动逼近用户尚未表达的底线。

本文系统的核心思想是把高风险推荐从一次性问答转化为可追溯的序贯决策。系统以 PostgreSQL 确定性 SQL 探针作为事实来源，避免大模型编造学校、专业、分数和学费等关键事实；以非补偿性单属性价值函数（SAVF）表达学费、地域、专业匹配等底线约束，避免严重违约项被学校层次等高分维度线性抵消；以置信上限（UCB）主动探测选择最值得澄清的偏好维度，并通过帕累托边际替代提问呈现具体取舍；再用 Bradley-Terry 后验更新和 Dempster-Shafer 式犹豫处理，把用户的接受、拒绝或模糊反馈转化为可计算的偏好状态。LangGraph 的 interrupt/resume 机制用于隔离探索期和终局推荐期，使系统先澄清关键不确定性，再生成可解释志愿方案。

在基准测试与消融实验中，完整系统相较静态检索以及去除主动探测或后验追踪的系统，表现出更低的偏好对齐误差和更准确的隐性维度识别。实验结果说明，完整系统的优势不来自大模型对初始话语的单轮猜测，而来自事实约束、主动探针、边际权衡和在线后验更新共同形成的认知闭环。该设计为高考志愿填报等高风险咨询任务提供了一种可审计、可交互、可扩展的系统设计路径。

关键词：高考志愿填报；大语言模型；推荐系统；系统设计；偏好建模；非补偿性效用

Abstract

This thesis designs and implements an LLM-driven Gaokao college application recommendation system. Gaokao application planning is a high-stakes, multi-objective, and fact-constrained decision task, where the first user query is often defensive and incomplete rather than a stable statement of true preference. Conventional Tool AI or retrieval-augmented generation systems accept the query, retrieve facts, and generate advice; they work for explicit questions but can mistake surface wishes for complete objectives. The proposed system reframes recommendation as evidence-driven mixed-initiative elicitation, using real admission evidence to construct trade-off questions and interactively reveal latent bottom lines.

The key idea of the proposed system is to turn high-stakes recommendation from one-shot answering into an auditable sequential decision loop. Deterministic SQL probes over PostgreSQL ground factual candidates and prevent the language model from inventing schools, majors, scores, ranks, or tuition values. Non-compensatory single-attribute value functions (SAVF) encode bottom-line constraints such as tuition, region, and major fit, so severe violations cannot be offset by school prestige. UCB active probing selects the dimension that most needs clarification; Pareto trade-off questions expose concrete substitutions; and Bradley-Terry posterior updating with Dempster-Shafer-style hesitant feedback handling converts user responses into a computable preference state. LangGraph interrupt/resume separates exploration from final recommendation.

Benchmark and ablation studies show lower preference-alignment error and more accurate latent-dimension discovery than static retrieval and variants without active probing or posterior tracking. The gain comes from factual grounding, active probes, marginal trade-offs, and online posterior updates rather than single-turn guessing, offering an auditable and interactive design path for high-risk advisory tasks.

Keywords: Gaokao planning; LLM; recommendation system; preference modeling; non-compensatory utility

目录

第一部分 毕业设计

1 绪论	3
1.1 研究背景	3
1.2 国内外研究现状	4
1.2.1 LLM 在教育与决策支持中的应用现状	4
1.2.2 RAG 技术从朴素检索到智能体增强 RAG 的演进	6
1.2.3 偏好启发与多轮交互技术的现有流派	8
1.3 问题定义与研究挑战	9
1.4 系统方案概述	10
1.5 研究内容与创新点	11
1.6 论文结构	12
2 核心算法实现	13
2.1 高考志愿推荐的统一问题定义与双范式建模	13
2.1.1 志愿推荐任务的统一形式化描述	13
2.1.2 静态混合检索范式下的单轮决策建模	14
2.1.3 交互式偏好澄清范式下的动态博弈建模	15
2.2 现有静态混合检索方案及其局限	16
2.2.1 混合检索基线的数据流实现	17
2.2.2 事实硬过滤与语义软排序机制	18
2.2.3 软约束召回的信息瓶颈	19
2.2.4 范式转移：从被动检索到主动偏好澄清	20
2.3 交互式偏好澄清范式下的推荐核心算法	20
2.3.1 非补偿性单属性价值映射	20
2.3.2 基于 UCB 的主动探测与帕累托候选对构造	22
2.3.3 Bradley-Terry 在线后验追踪	23
2.3.4 犹豫反馈与不确定性处理	24
2.3.5 终局效用寻优与事实生成边界隔离	25

3	志愿辅助决策系统设计与实现	27
3.1	系统需求分析与用例设计	27
3.2	系统总体架构	29
3.3	数据层构建与证据底座	31
3.3.1	招生事实与硬约束锁定	31
3.3.2	用户信息库与状态补全	31
3.3.3	标准化证据层与可谈判偏好轴	31
3.3.4	PostgreSQL 与 pgvector 的物理数据组织	32
3.3.5	专业树的标注与审校	34
3.3.6	地域树	36
3.4	智能体工作流与运行时状态机	37
3.4.1	LangGraph 工作流编排机制	38
3.4.2	运行时状态机与通信协议	39
3.4.3	主动探测的系统级集成	40
3.5	前端界面与交互展示	42
4	系统测试与实验评估	45
4.1	测试目标与研究问题	45
4.2	面向“冰山偏好”的系统受控测试集设计	46
4.2.1	显隐分离的沙盒测试机理	46
4.2.2	统一诊断测试集构造	47
4.3	实验配置与系统变体构建	49
4.4	参考基线横评结果	50
4.5	主消融实验结果	52
4.6	交互微观动力学与状态演化诊断	54
4.6.1	主动探测的有效性：从探测方向到权衡问题	55
4.6.2	主动探测的问题质量诊断	56
4.6.3	后验追踪的状态吸收诊断	57
5	总结与展望	59
5.1	全文工作总结	59
5.2	主要贡献	59

5.3 实验结论	60
5.4 局限性	60
5.5 后续工作	60
6 参考文献	61
作者简历	65

第一部分

毕业设计

1 绪论

1.1 研究背景

高考志愿填报是高中毕业生从考试成绩进入高等教育机会分配体系的关键环节。它不同于一般的信息检索任务，也不同于开放域闲聊问答。一次志愿咨询往往同时包含分数、位次、选科、专业、地域、家庭预算、风险偏好和就业预期等多类约束；系统给出的候选方案不仅需要语言上合理，更必须在录取事实上可达、在约束关系上自洽、在推荐理由上可追溯。对于考生和家庭而言，一次填报结果可能影响未来数年的学习机会、城市迁移、经济负担和职业起点。因此，志愿填报系统若要承担真实辅助决策功能，就不能只追求“回答得像专家”，还必须说明推荐依据来自哪里、哪些条件被保留、哪些偏好被放宽，以及这种放宽是否经过用户确认。

大语言模型的发展为教育咨询提供了新的交互形态。已有 GAKAO benchmark 与真实性评测研究说明，模型在考试问答或事实回答中取得较好语言表现，并不自然等价于高风险决策中的事实可靠^[1-2]。在志愿填报场景中，模型若仅凭参数记忆生成学校、专业、分数线或就业前景，就可能出现事实错配、年份混淆、政策误读和过度承诺等问题。检索增强生成能够把招生章程、历年录取分数、专业介绍和学校信息接入生成流程，从而降低模型仅凭记忆回答的风险^[3-5]。这类技术使系统可以从“背知识的聊天机器人”走向“带证据的咨询助手”，为教育决策中的事实核验提供基础。

然而，志愿填报的核心困难并不只是“缺少信息”。真实咨询中，用户经常以防御性和过度约束的方式开始表达需求，例如“只想留在浙江”“不接受冲刺”“学费不能太高”“专业不能换”。这些表达既可能是不可妥协的硬约束，也可能只是尚未被证据充分启发的初始偏好。若系统只按照初始表达做软约束召回，就会把候选筛选、偏好取舍和风险判断重新交还给用户，形成高风险决策中的信息瓶颈。相反，若系统直接替用户判断“可以放宽”，又会越过用户真实底线，产生看似合理但不可接受的推荐。

本文将这一现象称为“**冰山式偏好**”问题：用户显式说出的约束只是水面之上的部分，真正影响决策的底线、权重和可妥协边界隐藏在水面之下。传统 Tool

AI 的工作方式是被动执行用户请求：用户给出查询，系统检索材料，最后生成推荐或解释。这种模式适合事实问答，却不适合隐藏偏好仍未显化的决策场景。面向高风险志愿填报的系统应当从 **Tool AI** 走向 **Collaborative AI**：它不仅回答用户已经问出的问题，还应主动发现显式约束之间的张力，提出可审计的反事实比较，并在用户反馈中更新对其真实底线的理解。

因此，本文研究的最终目的，并非仅仅构建一个语言交互更流畅的志愿问答助手，而是面向**高风险多目标决策**中的“过度防御性约束”与“偏好幻觉”痛点，设计并实现一套面向**事实约束**的高考志愿推荐系统。该系统将大语言模型、结构化招生数据库、证据检索、偏好建模和多轮交互澄清组织为一条可运行的工程链路：以关系型确凿数据为不可逾越的**事实底线**，以**可解释候选对**呈现取舍关系，以用户反馈更新偏好状态，最终把模糊、隐藏的人类偏好转化为可计算、可追溯的推荐依据。

1.2 国内外研究现状

围绕大语言模型辅助教育决策，国内外研究大致形成了三个相关方向：第一是 LLM 在教育与决策支持中的应用，重点关注模型能否服务教学、学习和咨询任务；第二是 RAG 技术从朴素检索生成走向结构化、反思式和智能体化 workflow，重点关注事实可靠性与证据组织；第三是偏好启发与多轮交互技术，重点关注系统如何在交互中理解用户需求并更新决策模型。本文的问题处在**三者交叉处**：志愿填报既需要教育场景中的**语言理解**，又需要 **RAG 的事实约束**，还需要偏好引出的**主动交互机制**。

1.2.1 LLM 在教育与决策支持中的应用现状

从国际研究看，大语言模型在教育领域的应用已经覆盖智能辅导、学习材料生成、自动反馈、作业批改、问答答疑、教师备课和学习分析等多个方向。相关综述指出，LLM 能够利用自然语言交互降低学习支持门槛，并通过即时反馈和内容生成提升教育服务的可获得性^[6-7]。例如，在学习者端，模型可以根据学生问题生成分步解释、例题和练习；在教师端，模型可以辅助生成教学材料、总结学生表现、设计测验题目；在管理端，模型可以支持文本分析、风险识别和咨询

自动化。这些应用共同说明，LLM 已经从通用文本生成工具逐步进入教育工作流。

与此同时，教育场景对大语言模型提出了更高的安全和伦理要求。系统性综述显示，教育 LLM 应用虽然可以自动化题目生成、反馈生成和作文评价等任务，但仍面临事实错误、偏见、公平性、隐私保护、学术诚信、责任归属和人机角色边界等问题^[8]。这些问题在志愿填报中会被进一步放大：普通学习问答中的一次错误解释可以被教师或学习者纠正，而志愿推荐中的错误分数线、错误专业匹配或不恰当风险建议可能直接影响填报策略。因此，教育 LLM 的价值不能只由生成质量衡量，还要由事实可核验性、过程可审计性和人类最终决策权来约束。

国内研究和评测也开始关注中文语境下大模型的知识、推理和考试能力。C-Eval 面向中文语境构建多层级、多学科评测集，覆盖中学、大学和职业资格等不同难度任务^[9]；CMMLU 进一步从自然科学、社会科学、工程和人文等领域评估中文大模型的多任务理解能力^[10]；GAOKAO benchmark 则直接以高考相关题目检验模型在中国教育评价体系中的表现^[11]。这些 benchmark 为判断模型是否具备中文知识和考试推理能力提供了重要参照，但它们大多仍以静态题目或单轮回答为主要形式。对于高考志愿填报而言，系统不仅要回答“某个事实是什么”，还要帮助用户在多个可冲突偏好之间进行取舍，这要求研究对象从考试能力评测进一步扩展到过程性决策支持。

从国内应用语境看，志愿填报长期依赖政策文本、招生计划册、历年分数线、商业咨询平台和人工经验。此类服务能够提供大量信息，却也带来三个现实问题。第一，信息源分散且更新频繁，考生需要在学校官网、省考试院文件、专业目录和第三方解读之间反复核对。第二，许多规则以表格、批次、选科组合和专业组形式呈现，普通用户很难判断不同字段之间的约束关系。第三，家庭成员的目标并不总是一致：考生可能重视专业兴趣，家长可能重视城市和稳定性，咨询师可能强调录取概率。大语言模型可以把这些材料组织成自然语言解释，但若缺少结构化事实层和交互式偏好追踪，就容易把“解释材料”误当成“替用户决策”。

因此，教育 LLM 在志愿填报中的核心矛盾并不是模型能否生成一段表面完整的建议，而是系统能否在多源事实、用户偏好和风险边界之间保持稳定分工。一个合格的系统需要同时回答三类问题：事实层面，某个候选是否真实存在且录

取条件可达；偏好层面，用户是否愿意为某项收益接受某项代价；过程层面，系统是否曾经明确展示过这一代价并得到用户反馈。现有教育问答和考试 benchmark 主要覆盖第一类问题的一部分，而第二类和第三类问题仍缺少专门的任务定义和评价框架。

在决策支持领域，LLM 也被用于医疗、法律、金融、项目管理和教育咨询等高风险或半高风险场景。相关研究普遍强调，大模型适合作为信息整理、候选生成、解释生成和人机交互界面，但不应在缺乏证据和监管的情况下直接承担最终裁判角色^[11-12]。志愿填报与这些场景具有相似结构：用户需要的信息并非单一答案，而是基于事实、风险和个人偏好的综合建议。不同之处在于，志愿填报还具有强烈的家庭协商属性，用户偏好往往是不完整、迟疑甚至前后变化的。因此，本文将教育决策支持的关键问题概括为：如何在可核验事实基础上，通过多轮交互把隐性偏好转化为可讨论、可拒绝、可记录的决策变量。

1.2.2 RAG 技术从朴素检索到智能体增强 RAG 的演进

检索增强生成最初主要用于缓解语言模型在知识密集任务中的事实缺失问题。经典 RAG 框架在生成前检索外部文档，将非参数知识与生成模型结合起来^[3]。随着大模型进入实际应用，研究者逐渐发现，简单的“检索若干文档后拼接给模型”不足以支撑复杂任务：检索结果可能不相关，证据可能互相冲突，长上下文可能导致关键信息被忽略，生成阶段也可能偏离证据。RAG 综述通常将技术演进概括为朴素 RAG、Advanced RAG 和 Modular RAG：前者强调基本检索和生成链条，后两者进一步引入查询改写、重排、上下文压缩、迭代检索、结果校验和模块化编排^[4,13]。

在可靠性增强方面，Self-RAG 通过自我反思机制判断是否需要检索、检索内容是否有用以及生成内容是否被证据支持^[14]；Corrective RAG 关注在检索质量不足时进行纠偏，以减少低质量上下文对生成结果的污染^[15]；Adaptive RAG 根据问题复杂度动态决定检索策略^[16]。在复杂证据组织方面，GraphRAG 将图结构引入检索与总结流程，使系统能够在局部证据和全局结构之间建立联系^[17]；RAPTOR 通过树状组织和递归摘要提升长文档、多层次知识的检索效果^[18]；StructRAG 等工作强调在推理时将非结构化文本转化为更适合模型处理的结构化信息^[19]。这些研究共同推动 RAG 从“找几段相关文本”走向“围绕任务组织证据”。

近年来,智能体增强 RAG 进一步把检索、规划、工具调用、记忆和反馈纳入同一工作流。相关综述指出,智能体增强 RAG 不再把检索视为一次性前处理,而是允许智能体根据任务状态选择工具、分解问题、迭代检索并检查结果^[20]。在教育领域,RAG 已被用于课程问答、知识图谱辅助教育问答和大学招生咨询等任务^[5,21-22]。这些系统表明,外部知识库和智能体工作流可以显著改善教育问答中的知识更新和证据引用能力。

从数据形态看,志愿填报对 RAG 又提出了不同于普通文档问答的要求。招生事实大量存在于结构化或半结构化表格中,例如学校代码、专业组、选科要求、计划数、最低分、最低位次、学费和办学地点;政策解释和专业介绍则更多以自然语言文本存在。若系统只用向量相似度召回文本片段,就可能找得到相关介绍,却无法保证分数、位次、选科和年份同时一致;若系统只使用 SQL 硬过滤,又难以处理“想去发展好一点的城市”“不排斥相近专业”“希望就业稳一些”等模糊表达。由此可见,志愿填报需要的是结构化查询、语义检索和证据编排的协同,而不是单一检索。

此外,智能体增强 RAG 的开放性也带来可控性问题。自治智能体可以根据中间观察反复规划和调用工具,但高风险教育决策不适合让模型在黑盒推理链中自由扩展目标。系统需要明确哪些动作可以由模型规划,哪些事实必须由数据库返回,哪些结论必须经过规则或评测器核验。LLM 与数据管理的结合正在从单纯问答走向数据服务、工作流和智能体协同^[23],但在志愿填报中,这种协同必须进一步转化为可复现的状态流:每一次候选生成、偏好放宽和证据引用都应留下可回放记录。

不过,现有 RAG 与智能体增强 RAG 研究主要解决的是“如何获得更可靠的事实和更连贯的回答”。在志愿填报场景中,仅有可靠事实仍不够。一个系统可以准确检索某校某专业最低分,也可以正确解释某项招生政策,但这并不意味着它知道用户是否愿意为更好的专业质量接受跨省、是否愿意为更低风险牺牲学校层次、是否愿意为就业结果接受学费上浮。换言之,RAG 能提供证据,却不自动给出偏好边界。本文将 RAG 定位为事实证据层,而不是完整决策层,并进一步要求智能体在证据基础上执行偏好探测、帕累托比较和多轮反馈更新。

1.2.3 偏好启发与多轮交互技术的现有流派

偏好启发研究关注系统如何在用户无法一次性给出完整偏好时，通过问题、比较和反馈逐步学习用户需求。会话推荐系统是最接近本文问题的一类研究。与传统推荐系统一次性输出排序列表不同，会话推荐系统允许用户提出约束、询问理由、修改条件或反馈不满意，从而在多轮交互中改进推荐结果^[24-25]。早期工作已经将冷启动推荐建模为在线学习问题，系统通过少量问题快速建立用户偏好，并利用探索-利用策略选择更有信息量的问题^[26]。后续研究进一步指出，评价会话推荐系统不能只看最终命中率，还应关注交互效率、用户感知、解释质量和整体体验^[27]。

主动学习和 **bandit** 方法为“问什么问题”提供了理论工具。上下文 **bandit** 将推荐过程看作连续决策：系统根据用户和候选上下文选择一个动作，并根据反馈更新策略^[28]。**UCB** 类算法通过在收益估计中加入不确定性奖励，在利用已有高收益选项和探索未知选项之间取得平衡^[29]。在志愿填报中，这类思想可以转化为：系统不应随机询问“还想看什么”，而应优先选择最可能减少偏好不确定性的维度，例如专业底线、地域底线、风险底线或预算底线。这样，有限轮次的交互才能真正服务于偏好识别。

成对比较和多目标优化则为“如何表达取舍”提供了另一条路径。**Bradley-Terry** 模型将成对选择转化为潜在偏好强度估计，适合处理用户在两个候选方案之间的接受、拒绝或偏好反馈^[30]。多目标优化和帕累托最优理论强调，当多个目标无法同时达到最优时，系统应展示不同目标之间的边际替代关系，而不是用单一加权分数掩盖冲突^[31]。这与志愿填报高度契合：学校层次、专业匹配、地域距离、学费预算、风险等级和就业预期之间常常存在真实冲突。用户需要看到的是“如果放宽哪一项，会换来什么收益”，而不是一个难以解释的总分。

不过，将这些偏好启发方法直接迁移到志愿填报仍然存在差异。电商或内容推荐中的一次错误推荐通常只带来体验损失，而志愿填报中的错误试探可能被用户理解为系统在忽视其底线。因此，问题设计必须克制：系统不能为了探索而随意提出违反硬约束的方案，也不能把用户尚未确认的偏好推断写成确定结论。另一方面，真实用户反馈常常不是简单的“喜欢/不喜欢”，而是“这个专业可以，但城市太远”“如果学费只高一点可以考虑”“冲一冲可以，但不能全是冲刺”。

这些反馈同时包含接受、拒绝、条件接受和新约束，需要系统具备跨轮状态追踪能力。对话状态追踪和用户模拟研究说明，多轮评价必须关注状态变化和过程行为，而不是只检查最终答案^[32]。

由此，本文更倾向于把偏好启发理解为“证据驱动的澄清”而非“模型驱动的劝服”。系统提出的每一次放宽都应满足两个条件：其一，原始硬约束仍被保留或明确标注为待确认；其二，放宽带来的收益必须有可追溯证据支撑。只有在这两个条件下，主动提问才不会变成无依据的推荐话术。本文后续实现的志愿推荐系统正是在这一思想上组织：用确定性数据限制候选空间，用 UCB 选择最值得澄清的偏好轴，用成对比较更新偏好后验，再用自然语言把取舍呈现给用户。

综上，国内外现有研究已经分别在教育 LLM、RAG 可靠性和会话偏好启发方面取得进展，但三者之间仍存在断裂。教育 LLM 研究强调应用机会和伦理边界，却较少将志愿填报这类多约束高风险决策建模为可评测交互任务；RAG 研究强调事实增强和证据组织，却较少处理隐藏偏好的主动引出；会话推荐和 bandit 研究强调交互式偏好学习，却通常不要求每个候选都来自严格可审计的招生事实。本文的研究切入点正是这一空白：在真实数据约束下，将 RAG 的证据能力、智能体的流程编排能力和偏好引出的在线学习能力结合起来，使系统能够发现并验证用户没有明说的可妥协边界。

1.3 问题定义与研究挑战

本文研究的问题可以表述为：给定用户第一轮自然语言输入、真实招生数据库和若干标准化证据层，系统如何在不编造事实候选的前提下，通过少量多轮交互识别用户隐藏底线维度，并形成与真实偏好更一致的推荐解释。形式化地说，系统面对的不是一个完整可见的效用函数，而是一个需要在线引出的隐变量。用户初始话语只提供显式约束 q_0 ，系统需要通过候选对比较、反事实提问和反馈更新，得到偏好权重估计 $\hat{\mathbf{w}}$ ，使其尽可能接近隐藏权重 $\mathbf{w}^*$ 。

这一任务至少包含四个挑战。第一，**事实与偏好必须分离**。学校、专业、学费、地域、录取分和位次等事实只能来自确定性数据源，不能由语言模型自由生成。第二，**偏好建模不能简单采用线性补偿**。若一个方案严重违反用户预算或专业底线，即使学校层次更高，也不能被线性总分自动抵消。第三，**系统需要主动**

探测。隐藏底线不会仅靠一次性检索自然显现，系统必须选择最有信息增益的维度发问。第四，**交互系统需要记忆**。用户已经明确拒绝某一维度放宽后，系统若继续重复同一问题，不仅降低效率，也会破坏用户对系统的信任。

进一步地，该问题还要求评价方法从单轮答案正确性扩展到多轮过程正确性。若系统最终给出一个看似不错的推荐，但过程中曾经编造分数线、忽略用户拒绝、或在没有证据的情况下暗示某个专业就业更好，那么最终命中率并不能证明系统可靠。相反，若系统通过两三轮澄清逐步确认用户真实底线，即使推荐集合较小，也更符合高风险辅助决策的要求。因此，本文的研究挑战同时包含算法设计和评测设计：前者决定系统如何问，后者决定如何证明系统问得合理。

1.4 系统方案概述

为解决上述问题，本文设计并实现了一套大模型驱动的高考志愿推荐系统。系统的核心思想是把志愿推荐从“**一次性生成答案**”转化为“**事实约束下的多轮偏好澄清**”：首先由约束解析模块锁定分数、省份、选科、预算等显式条件，再由数据证据层返回事实可达候选；随后，推荐决策模块将候选映射为学校层次、专业匹配、学费预算、培养质量和地域距离等特征，并选择最值得澄清的偏好维度；最后，系统通过一轮或少量多轮 A/B 取舍问题吸收用户反馈，在偏好状态较稳定后生成最终的冲、稳、保推荐解释。

系统分工强调“事实由数据给出，表达由模型完成，取舍由用户确认”。大语言模型负责语义归一、澄清问题表达和最终解释组织；候选事实由 PostgreSQL、专业树、学费字段、质量画像和地域树等确定性证据源返回；偏好状态由**非补偿性价值映射**、**UCB 主动探测**、**Bradley-Terry 后验更新**和**D-S 式犹豫处理**共同维护。这种分工使系统既能利用大语言模型的语言理解和交互能力，又能避免其在高风险事实场景中直接承担不可核验的事实生成。

在系统行为上，本文系统形成“先约束、再澄清、后推荐”的交互节奏。第一步锁定用户明确给出的硬事实，避免模型在后续重写或解释中漂移；第二步在硬约束可行域附近寻找边际替代机会，例如相近专业、相邻地域、风险层级或学费预算上的可比较候选；第三步只向用户展示少量具有解释价值的问题，而不是把所有检索结果一次性抛给用户。这样，系统的主动性被限制在“帮助用户看见

取舍”这一范围内，不会变成替用户做价值判断。

从毕业设计定位看，本文系统不是单纯的会话推荐算法展示，而是由数据层、智能体服务层、推荐决策层、交互展示层和受控测试环境组成的完整工程闭环。数据层决定什么事实可以被主张，服务层决定状态如何流转，推荐决策层决定如何构造可解释取舍，测试层检验系统是否真的在不读取隐藏字段的情况下恢复用户真实偏好。

1.5 研究内容与创新点

围绕上述问题，本文的研究内容包括四个方面。第一，复现并分析一条面向高考志愿咨询的混合检索基线，明确其在软约束召回和一次性生成中的信息瓶颈。第二，构建招生事实表、专业树、学费字段、培养质量画像和地域树等证据层，使后续偏好探测能够回到可核验数据。第三，设计大模型驱动的轻量多角色智能体工作流，将语义归一、约束解析、确定性探针、主动探测、证据谈判和后验追踪组织为可回放状态图。第四，构建系统受控测试集，通过带隐藏底线的用户画像、自动对弈日志和消融实验评价系统是否真正识别隐性偏好。

在上述研究内容基础上，本文的主要创新点可归纳为三方面。

第一，理论与问题定义。本文提出面向高考志愿填报的冰山式偏好问题定义，指出传统 RAG 在高风险多目标决策中容易同时触发“偏好幻觉”和“线性补偿陷阱”。该定义将评价重点从“回答是否流畅”推进到“系统能否发现用户没有明说的真实底线”，为隐性偏好发掘提供了可讨论的问题边界。

第二，系统架构与推荐决策模块。本文完成大模型驱动的志愿推荐系统设计，将确定性事实检索、非补偿性单属性价值函数（SAVF）、UCB 主动探测和 Bradley-Terry 在线后验追踪结合起来。该系统把大语言模型限制在语义归一、探测规划和自然语言表达层，使其服务于事实约束下的可审计运筹学闭环，而不是替代事实裁判。

第三，系统测试与实证发现。本文构建系统受控测试集，用带隐藏底线的用户模拟器对完整系统、去除 UCB 的系统、去除后验追踪的系统与混合检索参考基线进行自动对弈。实验同时记录偏好对齐 MAE、推荐集 F1@N 和逐轮状态日志，用于证明主动探测与后验追踪模块对系统效果的贡献。

1.6 论文结构

本文采用本科毕业设计论文的五章结构，其中第 2-4 章构成主体研究内容：第 2 章给出高考志愿推荐问题定义与核心算法，第 3 章给出志愿辅助决策系统设计与实现，第 4 章给出系统测试与实验评估，第 5 章总结全文并讨论后续工作。章节之间的关系如图 1.1 所示。

第 1 章	第 2 章	第 3 章	第 4-5 章
研究背景与挑战	问题定义与核心算法	系统架构与工程实现	测试评估、局限性与展望
回答“为什么需要系统化志愿推荐”	回答“如何刻画隐性偏好”	回答“系统如何落地实现”	回答“是否有效以及边界在哪”

图 1.1: 论文结构与章节关系

具体而言，第一章介绍研究背景、国内外研究现状、问题定义、系统方案概述和研究内容与创新点。第二章先给出高考志愿推荐问题建模，再分析现有混合检索方案局限，并说明推荐决策模块的核心方法。第三章介绍系统需求、总体架构、数据证据底座、智能体工作流和前端交互展示。第四章报告测试集上的基准测试与消融实验结果。第五章总结全文并讨论后续工作。

2 核心算法实现

高考志愿辅助决策不仅需要庞大的底层数据支撑，更面临着如何精准捕获考生真实诉求的算法挑战。本章将从形式化建模出发，探讨该任务的本质与算法范式的演进逻辑。首先，给出高考志愿推荐任务的统一数学描述，并在同一框架下对比单轮静态检索与多轮动态博弈两种截然不同的建模范式（2.1 节）；随后，复盘并剖析现有静态混合检索方案在软约束召回与隐性偏好识别上遭遇的信息瓶颈（2.2 节）；最后，顺应从被动检索向主动澄清的范式演进，详细阐述本文提出的交互式偏好澄清范式下的推荐决策核心算法（2.3 节）。

2.1 高考志愿推荐的统一问题定义与双范式建模

高考志愿推荐表面上是“给出若干院校专业组合”的排序任务，实质上却是在强事实约束下对用户偏好进行识别、澄清与优化的决策问题。为了避免后续讨论仅停留在某一种工程实现上，本节首先给出统一的问题形式化描述，再分别说明静态混合检索范式与交互式偏好澄清范式如何在同一数学框架中展开。

2.1.1 志愿推荐任务的统一形式化描述

设用户首轮自然语言话语为 U_0 ，结构化招生事实库为 $\mathcal{D}$ ，多维证据集合为 $\mathcal{E}$ ，持久化用户信息库为 $\mathcal{P}$ 。其中， $\mathcal{D}$ 包含院校、专业、招生计划、历年最低分、最低位次、选科要求、学费和地域等可验证事实； $\mathcal{E}$ 则包含专业层级树、地域层级树、学校层次画像、培养质量证据、就业结果证据和政策文本等辅助判断材料； $\mathcal{P}$ 对应工程实现中的 `student_profiles` 表，用于保存考生省份、考试年份、分数、位次、选科、偏好省份/城市/专业、规避专业、学费上限和风险偏好等用户画像字段。系统首先从本轮自然语言输入 U_0 抽取新增或修正字段，同时按用户或会话标识 i 从 $\mathcal{P}$ 读取历史用户画像，并通过状态合并函数形成当前显式硬约束集合：

$$H = \{\text{score, province, subjects, year, batch, rank}\}, \quad (2-1)$$

其中约束集合的来源可写作：

$$H = \text{Merge}(\text{Parse}(U_0), \text{Retrieve}(\mathcal{P}, i)). \quad (2-2)$$

本轮输入负责覆盖用户明确更新的字段，用户信息库则补全本轮未重复说明但已知的分数、省份、选科、位次、预算和风险偏好等事实状态。若本轮输入与用户信息库在分数、选科、省份等关键硬约束上发生显式冲突，系统不静默覆盖，而是先触发澄清，再进入事实过滤。随后，系统在招生事实库中圈定绝对不可违背的事实可行域：

$$\mathcal{C}_{\text{hard}}(H, \mathcal{D}) = \{x \in \mathcal{D} \mid g_j(x, H) = 1, \forall g_j \in \mathcal{H}\}. \quad (2-3)$$

这里的 x 表示一个具体的院校-专业候选， g_j 表示分数、位次、选科、省份、年份、批次等硬规则校验函数。事实可行域 $\mathcal{C}_{\text{hard}}$ 是两种范式必须共守的底线：任何推荐候选都不能通过语言模型臆造、语义相似度补偿或排序得分抬升来突破该集合的事实边界。

在硬约束之外，用户还会表达专业兴趣、地域倾向、学校层次期待、学费预算、就业结果偏好和风险态度等软偏好。本文将这些偏好抽象为权重向量 w ，并定义候选 x 在给定权重下的效用为：

$$U(x; w) = \sum_{k \in \mathcal{K}} w_k \phi_k(x), \quad \mathcal{K} = \{\text{school, major, tuition, quality, geo, risk}\}. \quad (2-4)$$

其中 $\phi_k(x)$ 由 $\mathcal{D}$ 与 $\mathcal{E}$ 中的事实和证据共同计算。高考志愿推荐的终极优化目标，并不是简单复述用户首轮话语，而是在 $\mathcal{C}_{\text{hard}}$ 中寻找能够最大化用户真实隐性效用的推荐集合 $\mathcal{R}$ ：

$$\mathcal{R}^* = \arg \max_{\mathcal{R} \subseteq \mathcal{C}_{\text{hard}}} \sum_{x \in \mathcal{R}} U(x; w^*), \quad (2-5)$$

其中 w^* 表示用户对名校、专业、地域、预算、风险等维度的真实偏好权重。关键困难在于， w^* 通常并不等于用户第一句话中显式说出的要求，而是一个未知隐变量（Latent Variable）。用户可能因为信息不足、家庭压力、表达防御或尚未形成稳定判断而隐藏真实底线，因此系统需要围绕 w^* 的识别方式选择不同的决策范式。

2.1.2 静态混合检索范式下的单轮决策建模

传统混合检索方法在数学上对上述问题做了显著简化。该范式首先从 U_0 中抽取显式字段，形成硬约束集合 H 和表面偏好权重 w_{explicit} ，随后在 $\mathcal{C}_{\text{hard}}$ 内执行

关系型过滤、向量召回、语义重排和自然语言生成。其核心朴素假设可以写作：

$$w^* \approx w_{\text{explicit}} = \text{Parse}(U_0). \quad (2-6)$$

也就是说，系统将未知的真实隐性权重 w^* 强行等同于由用户第一轮显式话语提取出的表面偏好。由此，原本包含隐变量推断与多轮反馈的决策过程，被退化为一个单轮 ($T = 1$) 的“硬约束过滤 + 软相关性排序”映射问题：

$$\mathcal{R} = f_{\text{rank}}(\mathcal{C}_{\text{hard}}, U_0). \quad (2-7)$$

这一建模在事实问答或明确条件检索中具有工程合理性：当用户只要求“浙江考生 620 分能看哪些计算机专业”时，系统确实可以依靠结构化过滤和语义排序给出较稳健的候选列表。然而，在高考志愿这类高风险决策中，用户首轮话语往往只是偏好的不完全投影。例如，“最好留在江浙沪”可能是强地域底线，也可能只是对未知院校的不确定防御；“预算不要太高”可能是不可逾越约束，也可能存在小幅妥协空间。若静态混合检索范式直接把这些表面表达固化为 w_{explicit} ，系统就会把用户尚未确认的软偏好误读为真实目标。

因此，静态混合检索范式的理论局限集中体现为两点。第一是偏好幻觉：系统看似尊重了用户表达，实则只是在初始话语的表层语义附近排序，无法发现用户真正的取舍边界。第二是线性补偿陷阱：当名校、专业、地域、学费等维度被压缩进同一个相关性或效用分数时，某一维度的重大违约可能被其他维度的高分数值抵消，导致系统推荐出事实可达但决策上不可接受的候选。后文 2.2 节将以现有静态混合检索方案为对象，进一步剖析这一退化建模在软约束召回和隐性偏好识别上的信息瓶颈。

2.1.3 交互式偏好澄清范式下的动态博弈建模

为克服上述数学退化，本文将高考志愿推荐恢复为包含隐变量推断的在线主动学习与动态状态追踪过程。在交互式偏好澄清范式下，系统不再把 U_0 视为完整目标函数，而是将其作为关于 w^* 的初始观测。设第 t 轮系统状态为：

$$S_t = (\mathcal{C}_{\text{hard}}, \hat{w}_t, V_t, \mathcal{L}_t, \mathcal{E}), \quad (2-8)$$

其中 $\hat{w}_t$ 是对真实权重 w^* 的当前估计, V_t 表示各偏好维度的不确定性, $\mathcal{L}_t$ 保存历史候选对、用户反馈与证据来源。系统的目标是在有限轮交互内, 使 $\hat{w}_T$ 尽可能逼近 w^* , 并基于最终后验生成推荐集合。

每一轮交互中, 系统都会从事实可行域中构造具有帕累托张力的反事实候选对 (A_t, B_t) 。其中, A_t 通常代表当前后验下的安全基准方案, B_t 则在某一目标维度上要求用户付出明确代价, 同时在其他维度上提供可验证收益。候选对之间的特征残差定义为:

$$\Delta\Phi_t = \Phi(B_t) - \Phi(A_t). \quad (2-9)$$

系统随后向用户呈现这组边际取舍, 并获取有限动作反馈:

$$a_t \in \{\text{accept}, \text{reject}, \text{hesitate}\}. \quad (2-10)$$

不同于静态排序中的一次性点击或接受, a_t 被视为关于隐变量 w^* 的新观测。状态转移函数据此更新偏好后验:

$$S_{t+1} = F(S_t, A_t, B_t, a_t, \Delta\Phi_t). \quad (2-11)$$

这一建模把推荐过程从被动检索推进为动态博弈: 系统通过主动设计问题来压缩偏好不确定性, 用户通过接受、拒绝或犹豫表达对边际替代关系的判断。经过多轮交互后, 系统在事实可行域不变的前提下逐步修正 $\hat{w}_t$, 使其逼近真实隐性偏好 w^* 。由此, 后续算法设计的核心就不再是如何对首轮查询做更精细的语义匹配, 而是如何在有限轮次内构造最有信息量的候选对、稳健解释犹豫反馈, 并在最终阶段将后验偏好下推到事实候选空间中完成全局寻优。

2.2 现有静态混合检索方案及其局限

本文在前期实现中复现了一条面向高考志愿咨询的静态混合检索流程, 并将其作为后续推荐决策模块的对照基线。该流程将用户的自然语言问题转化为可检索、可过滤、可生成的交互链路: 底层由 LangGraph 式状态机约束节点流转^[33-34], 由状态访问器维护跨轮用户画像, 由查询重写模块把省份、分数、选科、专业意向等信息补全到查询表达中^[35], 再通过一致性校验与基础 SQL 过滤避免关键事实被大模型改写。其后, 系统使用关系数据库对分数、位次和地域等结构化条件

进行初筛，使用 BGE-M3 等双塔模型生成候选文本向量，并依托 PostgreSQL 的 pgvector 在数据库侧完成一阶向量粗排^[36]，再以 Qwen3-Reranker-8B 进行二阶重排^[37]，最后由生成模块组织答案。

这一架构完成了一个重要的工程验证：高考志愿咨询并非只能依靠静态网页检索，而可以被组织为带有状态追踪、意图路由、关系数据库过滤和语义重排的交互式智能体任务。其价值在于把志愿填报中的多个环节串接为一条可运行的图状态机，并初步解决了长上下文漂移、事实字段遗忘、检索材料过多和回答延迟等问题。在大模型服务层面，PagedAttention 等内存管理机制也说明吞吐与首字延迟优化本身是交互式系统的重要工程议题^[38]。对本文而言，这一复现不仅提供了与本文系统共享事实数据条件的参考基线，也为后文的约束解析、机会探测、证据谈判和后验追踪提供了可以被重新组织和研究的工程机制。

2.2.1 混合检索基线的数据流实现

本文在工程实现中将静态混合检索拆成五个串行阶段，如图 2.1 所示。第一阶段是显式约束归一：系统从用户话语中抽取分数、省份、城市、选科、专业、预算和风险偏好，并将口语化表达转成后续 SQL 与检索模型可以消费的字段。第二阶段是关系型硬过滤：系统优先使用 PostgreSQL 对录取最低分、最低位次、选科要求、地域、学费等字段做阻断式筛选，形成规模较小且事实可达的候选池。第三阶段是向量相关性打分：候选的专业说明、院校材料或知识文档通过 embedding 后端得到稠密向量，并在 pgvector 侧执行多意图加权相似度计算，用于补充专业方向、招生章程、就业说明等文本线索。第四阶段是二阶段重排：Qwen3-Reranker-8B 对前一阶段候选做更精细的语义相关性判断。第五阶段是冲稳保分段和自然语言解释：系统根据考生分数与候选最低分、最低位次之间的间隔，将候选组织为冲、稳、保等风险段。

这一实现的核心是“先事实可达，再语义排序”。若直接使用向量召回，高相似度文本可能来自不可达学校、错误年份或不满足选科的专业；若只使用 SQL 过滤，系统又难以处理“偏人工智能方向”“不要太偏理论”“就业好一点”等软表达。因此，基线采用关系标量和语义向量的组合：关系数据库负责排除事实上不可达或不合规的候选，embedding 与重排模型负责在可达候选中提升文本匹配质量。该流程在普通问答和一次性候选推荐中具有工程合理性，也为本文后续实




图 2.1: 混合检索基线的数据流实现

验提供了公平的强基线。

2.2.2 事实硬过滤与语义软排序机制

在混合检索方案中，系统并不把所有用户意图压缩为单一相似度分数，而是分层处理绝对的物理事实规则与模糊的语义匹配意图。前者由关系型数据库和业务规则承担：系统首先约束考生分数、年份、省份、选科、批次和地域等硬条件，再连接学校维表、专业维表、招生计划和选科要求表补齐候选字段。候选必

须具有可追溯的最低分、最低位次、学校名称、专业名称和选科要求，生成模块不能凭语言模型补写这些事实。对于风险段划分，系统计算考生分数相对最低分的差值，或在具备位次换算时使用位次间隔，使冲、稳、保不是主观标签，而是由事实字段导出的工程标签。

在事实可行域被锁定后，语义软排序才用于处理 SQL 难以表达的弱意图。以“计算机偏人工智能”“想去强一点的工科”“就业不要太差”为例，这些表达很难被单个字段完全覆盖，因此系统将候选文本和知识材料映射到向量空间，先用 BGE-M3 等双塔 embedding 生成静态特征向量，并由 pgvector 侧的向量计算完成一阶粗排。由于双塔召回为了吞吐会分别编码查询和候选，它对数字、否定、跨字段组合和细粒度约束不够敏感，容易产生语义漂移；因此系统再将粗排后的小候选集交给 Qwen3-Reranker-8B 进行二阶精排，在可控计算成本内提升语义匹配精度。

然而，上述分层机制的优化目标仍然是“把更相关的候选排在前面”。它并不回答用户真正犹豫的底线是什么，也不主动构造“牺牲地域能否换来学校层次提升”“小幅超预算是否值得换取专业质量证据”这类反事实问题。换言之，混合检索方案具有事实过滤和候选排序能力，但缺少偏好实验设计能力。

2.2.3 软约束召回的信息瓶颈

这一混合检索方案的核心限制来自软约束向量召回在高风险决策中的信息瓶颈。双塔模型和余弦相似度善于回答“哪些材料与用户表述相关”，却不天然回答“哪个条件可以被最小代价地放宽”“只改变一个偏好轴会带来多少收益”以及“候选方案是否在硬约束下仍然可达”。例如，当用户说“想读计算机、最好在江浙沪、只求稳”时，向量召回会把专业相似性、地域偏好和风险偏好混合进同一个相似度分数。二阶重排模型可以提升文本相关性，Reciprocal Rank Fusion 等方法也可融合多路排序结果^[39]，混合检索则能结合结构化与向量证据^[40]，但这些分数仍主要服务于材料排序，而不是直接给出面向决策的边际替代分析。

2.2.4 范式转移：从被动检索到主动偏好澄清

这一混合检索方案的工作方式可以概括为 **Tool AI**：用户提出问题，系统调用检索工具，随后生成答复。这一范式强调被动执行和材料相关性，在事实问答中是合理的。但在隐藏偏好场景中，系统需要承担更主动的澄清职责。它不仅要理解用户说了什么，还要识别用户没有说清楚、甚至有意防御性隐藏的底线。

本文系统在混合检索基础上进一步转向主动偏好澄清与决策协作。**Collaborative AI** 并不是让模型自由说服用户，而是在事实约束下组织可解释的比较：系统提出一个反事实候选对，说明方案 **B** 需要用户放宽哪一类偏好，同时说明它在其他维度带来的事实收益。用户据此判断该取舍是否可以接受。这样的交互比长列表推荐更接近决策协作：用户不需要一次读完大量候选，而是只需回答当前最能降低不确定性的边际问题。

2.3 交互式偏好澄清范式下的推荐核心算法

基于 2.1 节的动态交互博弈建模，并针对静态混合检索方案的局限，本节将详细阐述本文系统在交互式偏好澄清范式下的推荐决策核心算法。整个算法闭环由五个核心机制构成：首先，引入非补偿性单属性价值映射（2.3.1 节）以阻断灾难性妥协并保护事实底线；其次，使用置信上限（UCB）机制选择最高信息增益的偏好维度，并构造具备严格帕累托张力的反事实候选对（2.3.2 节）；随后，利用 **Bradley-Terry** 选择模型（2.3.3 节）与 **Dempster-Shafer** 证据理论（2.3.4 节）对用户的接受、拒绝或犹豫反馈进行在线后验追踪与不确定性更新；最后，在隐性偏好收敛后，执行带有事实生成边界隔离的终局效用寻优（2.3.5 节），生成最终的冲稳保推荐结果。

2.3.1 非补偿性单属性价值映射

传统多属性效用理论常以线性加权和表示总体价值，但高考志愿填报中存在明显的非补偿性底线。若用户预算明确不能超出，则再高的学校层次也不应自动抵消学费违约；若用户专业底线非常强，则名校但专业严重偏离的候选也不应被高分推荐。因此，系统先定义单属性价值函数（**Single-Attribute Value Functions, SAVF**），再用截断和惩罚保护不可补偿维度。

给定事实候选 x ，系统将其映射为五维特征向量：

$$\Phi(x) = [\phi_{\text{school}}(x), \phi_{\text{major}}(x), \phi_{\text{tuition}}(x), \phi_{\text{quality}}(x), \phi_{\text{geo}}(x)]. \quad (2-12)$$

学校层次采用离散阶梯映射，专业和地域采用层级放宽惩罚，质量证据采用局部 Min-Max 归一化。以培养质量为例，若当前候选池为 $\mathcal{C}$ ，原始质量分为 $q(x)$ ，则：

$$\phi_{\text{quality}}(x) = \frac{q(x) - \min_{z \in \mathcal{C}} q(z)}{\max_{z \in \mathcal{C}} q(z) - \min_{z \in \mathcal{C}} q(z) + \epsilon}. \quad (2-13)$$

局部归一化的意义在于，系统只比较当前硬约束可达区域附近的候选，而不是把所有学校、专业和城市放入同一个全局尺度。对于专业匹配，系统根据专业树中的放宽层级 $d_{\text{major}}(x)$ 计算：

$$\phi_{\text{major}}(x) = \max(0, 1 - \lambda_m d_{\text{major}}(x)). \quad (2-14)$$

地域距离同理，根据省、市和地域树得到 $d_{\text{geo}}(x)$ ：

$$\phi_{\text{geo}}(x) = \max(0, 1 - \lambda_g d_{\text{geo}}(x)). \quad (2-15)$$

学费预算采用非补偿性截断。设用户预算为 b ，候选学费为 $c(x)$ ，若预算被判定为硬底线，则超预算候选直接进入一票否决区间：

$$\phi_{\text{tuition}}(x) = \begin{cases} 1 - \frac{c(x)}{b + \epsilon}, & c(x) \leq b, \\ -M, & c(x) > b \text{ and } \text{hard}(b) = 1, \\ \max\left(0, 1 - \frac{c(x) - b}{b + \epsilon}\right), & c(x) > b \text{ and } \text{hard}(b) = 0. \end{cases} \quad (2-16)$$

其中， M 表示远大于任一归一化正向收益上界的极大常数。本文将这一设计称为极大惩罚势垒（**Extreme Penalty Barrier**）：当某一维度被用户确认为不可逾越底线时，系统不再让该维度以普通负分参与线性折中，而是用 $-M$ 将候选推入一票否决区域。这样，在后续加权求和计算中，学校层次、培养质量或地域收益都难以补偿该底线违约，从而降低线性补偿陷阱带来的误排风险。

总体效用仍可写作加权和：

$$U(x; \mathbf{w}) = \sum_{k \in \mathcal{K}} w_k \phi_k(x), \quad \mathcal{K} = \{\text{school}, \text{major}, \text{tuition}, \text{quality}, \text{geo}\}. \quad (2-17)$$

但由于 ϕ_{tuition} 等维度可以进入极端惩罚区间，该效用不再是完全补偿性的线性偏好，而是在可解释价值映射上嵌入底线保护。

2.3.2 基于 UCB 的主动探测与帕累托候选对构造

若系统在多轮交互的初期，仅贪婪地按当前后验均值 $\mathbf{w}_t$ 推荐全局效用最高的候选，极易陷入带有严重偏差的局部最优解。这种“过早利用 (Premature Exploitation)”无法有效试探出被用户防御性话语掩盖的真实底线。因此，推荐决策模块引入了最大化期望信息增益 (Max-EIG) 机制，并使用置信上限 (Upper Confidence Bound, UCB) 算法进行主动学习的工程近似。

系统为每个偏好维度 $k \in \mathcal{K}$ 同步维护后验均值 $w_{t,k}$ 和不确定性方差 $v_{t,k}$ 。在第 t 轮交互时，系统计算各维度的置信上限打分，以此决定下一轮优先探测的目标维度：

$$\text{UCB}_{t,k} = w_{t,k} + \beta \sqrt{v_{t,k}}. \quad (2-18)$$

$$k_t = \arg \max_{k \in \mathcal{K}} \text{UCB}_{t,k}. \quad (2-19)$$

选定高信息增益维度 k_t 后，系统需要构造一个反事实候选对 (A_t, B_t) 对用户进行“帕累托压力测试”。直观上，若两个候选方案高度同质，用户的选择将难以提供新的偏好信息；若要识别用户在 k_t 维度上的接受边界，系统需要设计一个具有“代价-收益”差异的抉择。

具体而言，推荐决策模块将候选对抽取建模为一个约束条件下的特征散度最大化问题。系统首先将当前隐性效用得分最高的候选锁定为安全基准解 A_t (Baseline Solution)，即 $A_t = \arg \max_{x \in \mathcal{C}} U(x; \mathbf{w}_t)$ 。随后，在候选池 $\mathcal{C}$ 中寻找一个与 A_t 的特征张量 L_1 散度最大，且严格满足“在目标维度 k_t 上产生显著代价，而在其他维度换取显著收益”的最大张力妥协解 B_t (Challenger Solution)：

$$\begin{aligned} B_t &= \arg \max_{x \in \mathcal{C}} \|\Phi(x) - \Phi(A_t)\|_1, \\ \text{s.t. } &\phi_{k_t}(x) - \phi_{k_t}(A_t) \leq -\epsilon_{\text{loss}}, \\ &\exists j \neq k_t, \quad \phi_j(x) - \phi_j(A_t) \geq \epsilon_{\text{gain}}. \end{aligned} \quad (2-20)$$

其中， ϵ_{loss} 和 ϵ_{gain} 为预设的特征差分容忍阈值。上述非支配帕累托约束 (Non-dominated Pareto Constraint) 在数学上确保了：妥协解 B_t 必须要求用户牺牲目标维度 k_t (试探底线)，同时必然在至少一个维度 j 上给予正向跃迁 (提供补偿)，从而构成一对真实的边际替代关系，而非无意义的单向劣解。

通过上述严格的数学寻优，数据底座向证据谈判器（Evidence Negotiator）输出了带有明确方向的特征残差张量 $\Delta\Phi_t$ 。谈判器的大语言模型据此生成自然语言的边际替代率（Marginal Rate of Substitution, MRS）提问：“如果保留方案 A，您将守住当前底线；若改看方案 B，您需要放宽/牺牲代价维度 k_t ，但能换取收益维度 j 的显著跃迁，您是否愿意接受这一妥协？”

值得强调的是，该设计衍生出事实边界阻断机制（Factual Circuit Breaker）：若上述约束优化无解，即底层数据库中客观上不存在能通过牺牲 k_t 换来其他真实收益的方案，系统将触发阻断。谈判器会向用户反馈“本轮候选不足以形成取舍”，并停止生成放宽建议。该机制把偏好探测限制在真实可达的招生数据内，减少大语言模型为了完成试探任务而虚构收益的风险。

2.3.3 Bradley-Terry 在线后验追踪

给定候选对 (A, B) ，定义特征差：

$$\Delta\Phi_t = \Phi(B_t) - \Phi(A_t). \quad (2-21)$$

系统使用 Bradley-Terry 选择模型刻画用户选择方案 B 的概率：

$$P_t(B) = \sigma(\tau \mathbf{w}_t^\top \Delta\Phi_t) = \frac{1}{1 + \exp(-\tau \mathbf{w}_t^\top \Delta\Phi_t)}. \quad (2-22)$$

若用户明确接受 B ，记 $y_t = 1$ ；若明确拒绝，记 $y_t = 0$ 。单轮对数似然为：

$$\ell_t(\mathbf{w}) = y_t \log P_t(B) + (1 - y_t) \log(1 - P_t(B)). \quad (2-23)$$

对权重执行逻辑斯蒂梯度上升：

$$\tilde{\mathbf{w}}_{t+1} = \mathbf{w}_t + \eta \tau (y_t - P_t(B)) \Delta\Phi_t. \quad (2-24)$$

为保持权重在概率单纯形上，系统再执行投影和归一化：

$$\mathbf{w}_{t+1} = \Pi_{\Delta}(\tilde{\mathbf{w}}_{t+1}), \quad \Delta = \left\{ \mathbf{w} : \sum_k w_k = 1, w_k \geq 0 \right\}. \quad (2-25)$$

2.3.4 犹豫反馈与不确定性处理

真实用户并不总是明确接受或拒绝。系统受控测试日志中去除主动探测模块常收到“这个问题没问到我的真正底线，我先保留。”这类反馈。若系统把犹豫直接当成接受或拒绝，会误改均值；若完全忽略，又无法表达当前问题无效。偏好追踪器因此采用 Dempster-Shafer 风格的证据处理：明确反馈更新均值，犹豫反馈保持均值基本不变，但提升相关维度方差。

设用户反馈属于三类 $\mathcal{R} = \{\text{accept}, \text{reject}, \text{hesitate}\}$ 。当 $r_t = \text{hesitate}$ 时：

$$\mathbf{w}_{t+1} = \mathbf{w}_t, \quad v_{t+1,k} = v_{t,k} + \gamma |\Delta\phi_{t,k}|. \quad (2-26)$$

这一机制使系统在“问题没有问到底线”时不会过度学习错误方向，但会意识到当前后验仍不确定。下一轮 UCB 会继续寻找高不确定维度，从而避免随机泛化追问，也避免重复确认同一个已经被拒绝的底线。

算法 2.1 汇总了上述模块在一次完整交互中的调用顺序。下面的伪代码强调每轮如何在硬约束、主动探测和后验更新之间闭环。

算法 2.1 主动偏好澄清流程

Input: $u_0, \mathcal{P}, i, \mathcal{E}, \mathcal{K}, T$
Output: $R, \mathcal{L}$

```

1:  $(H, \mathbf{w}, \mathbf{v}) \leftarrow \text{PARSEANDMERGE}(u_0, \mathcal{P}, i)$ 
2:  $\mathcal{L} \leftarrow \emptyset$ 
3:  $\mathcal{C} \leftarrow \text{RETRIEVE}(H, \mathcal{E})$ 
4: for  $t = 0$  to  $T - 1$  do
5:   if  $\text{STOP}(\mathbf{w}, \mathbf{v}, t)$  then
6:     break
7:   end if
8:    $k \leftarrow \arg \max_{j \in \mathcal{K}} (w_j + \beta \sqrt{v_j})$ 
9:    $(A, B, \Delta\Phi) \leftarrow \text{SELECTPAIR}(\mathcal{C}, k)$ 
10:   $q \leftarrow \text{QUERY}(A, B, k)$ 
11:   $\text{INTERRUPT}(q)$ 
12:   $r \leftarrow \text{RESUME}$ 
13:  if  $r \in \{\text{accept}, \text{reject}\}$  then
14:     $y \leftarrow \mathbb{I}[r = \text{accept}]$ 
15:     $p \leftarrow \sigma(\tau \mathbf{w}^\top \Delta\Phi)$ 
16:     $\mathbf{w} \leftarrow \Pi_\Delta(\mathbf{w} + \eta\tau(y - p)\Delta\Phi)$ 
17:  else
18:     $\mathbf{v} \leftarrow \mathbf{v} + \gamma |\Delta\Phi|$ 
19:  end if
20:   $\mathcal{L} \leftarrow \mathcal{L} \cup \{(q, r, A, B, \mathbf{w}, \mathbf{v})\}$ 
21: end for
22:  $R \leftarrow \text{REPORT}(\mathbf{w}, \mathcal{L})$ 
23: return  $(R, \mathcal{L})$ 

```

2.3.5 终局效用寻优与事实生成边界隔离

当偏好探测的多维不确定性总和收敛至预设阈值，或达到最大交互上限时，系统状态机将从“主动探索 (Exploration)”切入“全局利用 (Exploitation)”阶段，执行最终的志愿表生成。此时，系统的核心任务是如何利用推断出的隐性偏好权重 $\mathbf{w}_{\text{final}}$ ，在海量底层数据中完成全局候选方案的寻优与组装。

为了降低高风险决策中的“偏好幻觉”风险，推荐决策模块在此阶段采用“硬约束召回-效用下推重排-显示性偏好解释”的三阶段流程。首先是基于硬约束的物理可行域锁定。确定性探针跳过所有软约束偏好，仅基于考生的分数、位次、省份和选科等显式硬底线，执行 SQL 关系型过滤，从底层数据库中截取出一个事实可达的物理可行域 $\mathcal{C}_{\text{hard}}$ 。

其次是基于隐性权重的全局效用下推与重排 (Utility Push-down & Re-ranking)。系统提取偏好追踪器最终收敛的隐性权重向量 $\mathbf{w}_{\text{final}}$ ，在纯数学内存层面对可行域内的每一个候选方案 $x \in \mathcal{C}_{\text{hard}}$ 提取非补偿性特征 $\Phi(x)$ ，并执行内积运算得到全局期望效用得分：

$$U(x; \mathbf{w}_{\text{final}}) = \mathbf{w}_{\text{final}}^{\top} \Phi(x) = \sum_{k \in \mathcal{K}} w_{\text{final},k} \phi_k(x). \quad (2-27)$$

为契合高考志愿填报真实的风险对冲策略，系统根据考生分数与候选历史最低分的“分差 (Score Margin)”，将可行域划分为“冲 (Reach)”、“稳 (Match)”、“保 (Safety)”三个风险梯队。在每个风险梯队内部，系统依据效用得分 $U(x; \mathbf{w}_{\text{final}})$ 降序排列，截取头部候选构成最终的物理推荐矩阵。在此过程中，非补偿性的极大惩罚势垒继续生效，使违背安全底线的候选难以进入最终推荐序列。

最后是生成边界约束与偏好解释。在完成上述效用寻优后，系统才将最终的冲稳保序列与权重字典交付给大语言模型。在此环节，大语言模型不能直接新增学校或改写事实字段，其上下文被限制在数学引擎输出的候选子集内。大语言模型只负责将底层推断逻辑翻译为人类可读的解释，例如：“系统推断出您更重视核心专业的匹配度，但对地域具有一定妥协空间，因此在‘稳妥’梯队为您优先排序了以下方案”。

这一隔离设计从底层避免了“模型为了迎合用户情绪而捏造录取分数或产生线性补偿幻觉”的路径。对高考志愿填报而言，这种严苛的事实与生成边界约

束是智能决策系统建立人类信任的前提。

3 志愿辅助决策系统设计与实现

本章从工程实现角度说明大模型驱动的高考志愿推荐系统如何落地。与上一章聚焦核心算法不同，本章强调需求、架构、数据底座、智能体状态流和交互界面的整体组织：数据层负责事实可达性与证据来源，智能体层负责语义归一、探针规划和状态恢复，推荐决策层负责主动探测和后验追踪，前端层负责把取舍问题与推荐解释呈现给用户。通过这种分层叙事，本文将原先分散在数据、算法和评测章节中的工程内容重新收束为一个完整的系统设计章节。

3.1 系统需求分析与用例设计

志愿辅助决策系统面向两类业务相关使用者及两个外部支撑系统展开设计。考生和家长是系统的主参与者，他们需要用自然语言发起志愿咨询、表达不可妥协条件、参与偏好妥协谈判，并最终获取冲稳保志愿报告；系统管理员负责维护专业树、地域树、画像数据、受控测试画像和交互推理日志，保证系统在受控测试画像和版本迭代中保持可复查。系统外部的大语言模型 API 只承担语义交互、反事实探测问题生成和推荐解释生成，招生数据库承担硬约束检索、候选证据、专业树、地域树和画像数据的事实来源。由此，系统需求不仅包括传统推荐系统的候选召回、排序和解释，还包括硬约束锁定、事实生成边界隔离、主动偏好发掘、后台审计流程和数据维护等工程能力。

表 3.1 从功能类别、功能描述和验收要点三个维度汇总上述需求。在此基础上，表 3.2 将核心业务用例与参与者对应起来，为后续 UML 用例图提供文本索引。图 3.1 将上述需求进一步整理为 UML 用例关系。左侧的考生/家长是业务主参与者，负责发起初始咨询、参与偏好妥协谈判并获取最终报告；右侧的大语言模型 API 和招生数据库被建模为外部系统参与者，用于强调自然语言能力与事实证据能力的边界隔离；系统管理员负责受控测试画像回归、日志审计以及专业树、地域树与画像维护。该用例划分把真实咨询流程、外部服务依赖和后台审计流程分开呈现，避免将实验复查活动误写成面向用户的业务动作。

从业务用例角度看，用户首先发起初始志愿咨询，系统在该用例中包含不可妥协硬约束提取；当输入字段不足时，引导补充缺失条件作为扩展用例触发。进入主动偏好发掘阶段后，用户参与偏好妥协谈判，系统包含反事实探测问题构

表 3.1: 志愿推荐系统功能需求表

需求类别	功能描述	验收要点
用户意向采集	支持考生/家长以自然语言发起志愿咨询并输入分数、选科、专业、地域和预算偏好。	必要字段缺失时触发补充条件引导，不擅自补写分数、选科或省份。
硬约束提取	从用户表达中提取不可妥协硬约束，并调用招生数据库进行候选可达性判断。	分数、选科、年份和招生事实由数据库或审校画像支撑。
证据边界隔离	区分大语言模型 API 与招生数据库的职责边界。	大模型不生成事实候选，事实字段均能追溯到招生事实表、专业树、地域树或画像数据。
主动偏好发掘	构造反事实探测问题，引导用户参与偏好妥协谈判并澄清犹豫底线。	每轮问题围绕一个主要取舍，不输出无证据收益。
推荐报告生成	输出冲稳保志愿报告，并给出显示性偏好解释。	候选先满足硬约束，再按全局效用下推重排结果组织。
后台审计流程	支持受控测试画像回归、交互推理日志审计和专业树、地域树与画像维护。	支持系统管理员回放画像、定位错例和检查证据来源。




图 3.1: 志愿推荐系统 UML 用例图

表 3.2: 核心用例与参与者

用例	参与者	基本流程
发起初始志愿咨询	考生/家长	输入成绩、选科和偏好，系统提取不可妥协硬约束并在字段缺失时引导补充。
参与偏好妥协谈判	考生/家长	系统基于事实候选构造反事实探测问题，用户接受、拒绝或犹豫，系统更新偏好状态。
获取冲稳保志愿报告	考生/家长	系统执行全局效用下推重排，输出冲稳保候选与显示性偏好解释。
执行受控测试画像回归	系统管理员	使用受控测试画像检验硬约束、事实检索、偏好澄清和推荐生成链路。
审计偏好交互推理日志	系统管理员	回放逐轮问题、反馈、权重变化和证据引用，定位异常交互。
维护专业树、地域树与画像数据	系统管理员	更新专业树、地域树、质量画像和招生事实字段，保证证据底座可用。

造，并在用户反馈模糊或犹豫时触发底线澄清扩展。最终推荐阶段包含全局效用下推重排和显示性偏好解释生成：前者依赖招生数据库，后者依赖大语言模型 API。后台用例则为系统管理员提供受控测试画像回归、推理日志审计和数据维护入口，从而把本文已有的受控测试画像转化为系统质量保障流程的一部分。

3.2 系统总体架构

本文系统采用四层架构组织，如图 3.2 所示。第一层是交互表示层，负责承载用户显式目标、对话消息、澄清问题、候选解释和最终推荐结果；第二层是智能体服务层，负责语义归一、约束解析、探针调度、状态恢复和节点间通信；第三层是推荐决策层，负责非补偿性价值映射、UCB 主动澄清、候选对构造、Bradley-Terry 后验追踪和犹豫反馈处理；第四层是数据证据层，提供用户信息库、招生事实库、专业树、地域树、质量画像、学费字段和文本向量材料。

该架构的关键不是简单叠加数据库、语言模型和评测器，而是把事实证据、偏好澄清和推荐排序组织成闭环：数据证据层限定什么事实可被主张，推荐决策层决定哪些偏好轴值得澄清，智能体服务层把这些判断转化为可执行状态流，交互表示层再把用户的接受、拒绝或犹豫反馈写回系统状态。由此，系统不再只是回答用户“有哪些学校”，而是帮助用户理解“在哪个偏好轴上放宽最划算”。

3.3 数据层构建与证据底座

3.3.1 招生事实与硬约束锁定

基础招生事实来自招生数据库，主要包含录取分数、学校录取分、分数位次段、批次线、招生计划、学校信息和学费字段。这些表提供硬约束判断所需的事实依据：候选是否可达、是否满足选科、是否在预算内、是否保留必要专业或地域约束。与普通文本检索相比，结构化数据库的优势在于可复现和可审计；每个候选都可以追溯到具体字段。

本文将分数、位次、选科等条件视为默认不可破坏的硬约束。智能体的放宽行为不是任意扩大搜索空间，而是在硬约束锁定后的可行域内寻找可谈判偏好轴。这样的设计避免了高风险决策中常见的“语言上合理但事实不可达”的推荐，也使后续帕累托谈判具有明确边界。

3.3.2 用户信息库与状态补全

除招生事实库外，系统还维护一张面向会话状态的持久化用户信息库。工程实现中，该部分对应 `student_profiles` 表，用于保存考生省份、考试年份、分数、位次、选科组合、偏好省份/城市/专业、规避专业、学费上限和风险偏好等画像字段。它的作用不是提供院校录取事实，而是为约束解析器提供跨轮状态补全：当用户本轮没有重复说明分数、选科或预算时，系统可以从用户信息库读取已确认字段，与本轮自然语言抽取结果合并后形成当前约束状态。

用户信息库只保存用户显式给出或历史交互中已经确认的画像信息，不作为受控评测中隐藏底线字段的读取入口。若本轮输入与库中已有画像在分数、选科、省份等关键硬约束上出现明确冲突，系统不直接静默覆盖，而是先触发澄清问题，待用户确认后再进入招生事实过滤。这样的状态补全机制使系统既能避免长上下文遗忘，又能保持高风险字段的可审计边界。

3.3.3 标准化证据层与可谈判偏好轴

在基础事实之上，本文构建多类标准化证据层。专业树将原始专业名组织为面向决策的分阶段放宽结构，用于支持专业树放宽。学费字段来自招生计划表，

用于构造预算附近的小幅超预算谈判。学校-专业质量画像聚合专业排名、学科评估、特色专业、重点专业和满意度，用于支持专业质量证据。专业就业结果画像聚合就业排名、行业、岗位和薪资分布，用于就业导向偏好启发。地域树由地理邻近树和城市层级树两类证据组成，用于把“别太远”“想去好城市”等模糊表达转化为可讨论的地域偏好。与 GraphRAG 和 RAPTOR 等面向图结构或层级摘要的 RAG 方法类似，本文强调证据组织结构本身会影响后续回答能否跨越局部片段并形成可解释判断^[17-18]。

这些证据层并不改变录取事实，而是为“为什么值得放宽”提供可解释理由。例如，专业质量提升必须对应质量画像中的可追溯证据；就业结果提升必须对应就业排名、行业或薪资等字段；地域树只能说明候选城市与用户地域偏好之间存在经审校的结构关系，不能直接推出就业机会、生活成本或城市生活质量收益。

3.3.4 PostgreSQL 与 pgvector 的物理数据组织




图 3.3: PostgreSQL 与 pgvector 证据结构图

从物理实现看，本文数据层不是一个抽象“知识库”，而是一组可复核的 PostgreSQL 关系表、标准化画像表、层级 JSON 文件和可选文本向量库的组合。结构化候选查询以录取分数、招生计划、学校、专业和选科要求等表为主，质量

与就业扩展分别落在质量画像表和就业画像表。图 3.3 展示了这些对象之间的工程分工。左侧基础事实表决定候选是否可达，中间画像表解释候选在哪个证据轴上具有收益，右侧文本向量库服务于解释材料和 RAG 基线。本文系统的事实候选不直接来自大模型生成，也不直接来自自由文本相似度，而是由确定性探针在这些结构化对象上执行查询后返回。为避免数据层说明停留在图示层面，表 3.3 进一步列出核心表或文件、关键字段和系统职责。这种物理组织方式对应系统证据底座的可追溯设计：每一个候选行都必须携带其来源字段，每一个收益解释都要能回到具体表或 JSON 节点。

表 3.3: 核心数据库表与字段职责

表或文件	关键字段	在系统中的职责
学校 维表	name, province, city, is_985, is_211, ranking	提供学校层次、地域和排名证据，用于学校收益与地域放宽判断
专业 维表	major_code, discipline_category, level, name,	提供规范专业维表，与真实招生专业名共同支撑专业匹配
录取 分数表	year, min_score, min_rank, requirement_normalized	专业级录取事实，是候选可达性、风险分段和硬约束锁定的主表
招生 计划表	tuition, plan_count, subject_requirement score, rank,	提供招生计划与学费，支撑预算性价比放宽
用户 信息表	selected_subjects, tuition_max, risk_preference normalized	对应 student_profiles, 为约束解析和状态合并提供持久化用户画像
选科 要求表	_subjects, requirement_type	将原始选科要求转成可查询数组，使用 GIN 索引支持选科匹配
质量画像表	quality_score, quality_tier, evidence_sources	聚合专业排名、学科评估、特色/重点专业和满意度证据
就业画像表	outcome_score, employment_rank, salary_distribution	提供就业排名、行业、岗位和薪资分布证据
知识 文档表	doc_type, content, metadata, embedding vector(1536)	承载解释性文本和 Tool AI 混合检索材料；不作为系统事实候选的唯一来源
专业树/ 地域树文件	node_id, parent_id, review_status, relaxation_target	提供分阶段专业放宽和地域树替代关系

3.3.5 专业树的标注与审校

专业树是本文数据贡献和推荐决策模块之间的桥梁。它不是普通专业目录的复述，而是面向高考志愿决策的可解释放宽结构：当用户坚持某一专业名称时，系统需要知道哪些名称属于同一叶子簇，哪些属于同一父类，哪些只是更远的相关方向。若缺少这一层树结构，专业放宽就会退化为黑盒向量相似度，用户只能看到一串“看起来相关”的候选，却无法判断放宽代价是否合理。

表 3.4: 专业树的全量标注与审校流程

阶段	操作	产出与作用
人工骨架	先定义面向志愿决策的专业大类、父类和叶子簇，并为每个叶子簇设置包含词与排除词。	形成可解释的放宽边界，避免把语义相近但决策含义差异很大的专业混在一起。
真实名称扫描	扫描录取分数表中的原始专业名称，共得到 22,759 个去重名称，覆盖 140,995 条录取记录。	将专业树构建对象从标准目录转向真实招生文本，保证后续系统面对的是实际会出现在数据库中的专业名。
规则挂载	使用包含/排除规则把专业名挂载到叶子簇。	初步挂载 18,587 个去重专业名和 116,687 条记录，剩余 4,172 个去重专业名进入全量候选集合。
全量候选	对全部 4,172 个规则未挂载专业名生成 Top-10 叶子簇候选。	取消高频 Top 500 截断，使所有长尾专业名都进入可审计挂载流程。
低置信复核	以 0.35 为阈值，对 934 条低置信候选调用 DeepSeek-R1 复核。	881 条完成模型复核，653 条改变原 probe 建议；53 条模型弃权样本回退到 probe top-1，并标记为需人工抽检。
最终合成	合并规则挂载、高置信 probe、低置信复核和 fall-back 记录。	最终 22,759 个原始去重专业名、140,995 条录取记录全部进入某个叶子簇，剩余未挂载为 0。

真实招生数据中的专业名称具有明显噪声。一所学校可能在专业名中加入培养方向、括号备注、实验班、合作办学、双学位或大类招生说明；同一专业在不

同学校也可能以不同文本形式出现。因此，本文没有直接采用外部专业目录作为最终标签，而是以数据库中的真实招生专业名为观测对象，构建“人工骨架-规则挂载-全量候选-低置信复核-可审计合成”的 human-in-the-loop 标注流程。该流程见表 3.4。最终专业树的规模如表 3.5 所示。

表 3.5: 专业树全量覆盖统计

统计项	数值
节点总数	82
第 0 层大类	8
第 1 层节点	22
叶子簇	52
原始去重专业名挂载覆盖	22,759 / 22,759
原始录取记录挂载覆盖	140,995 / 140,995
规则未挂载专业名全量候选	4,172
DeepSeek-R1 低置信复核/弃权	934
需后续人工抽检 fallback	53
剩余未挂载专业名	0
叶子 observed names 去重条目	22,767




图 3.4: 专业树全量覆盖的总体结构与典型分支

图 3.4 以局部展开的方式展示专业树的总体结构与典型高频分支。该图只呈现若干代表性路径，用于说明专业树如何服务分阶段放宽；完整覆盖规模仍以表 3.5 和专业树标注汇总材料为准。

专业树同时服务数据层和测试层。在系统侧，专业树使“同叶子簇、同父类、相关大类、任意专业”成为可解释的分阶段专业放宽路径；在评测侧，它用于构造专业约束放宽画像、隐藏志愿集合和事实裁判规则。

3.3.6 地域树

地域树借鉴了专业树的思想，但其功能更加克制。地理邻近树用于表达“离家近、江浙沪、华东”等距离或区域偏好；城市层级树用于表达“大城市、强省会、城市资源”等偏好线索。本文不把城市层级树视作客观收益，而把它视作偏好显性化工具：系统可以据此提出“是否愿意从原地域要求放宽到某个相邻板块或城市层级树节点”的问题，但最终收益仍必须由学校层次、专业质量、就业结果或风险结构等可核验证据支撑。图 3.5 并排展示地理邻近树与城市层级树的局部结构。




图 3.5: 经人工审校的地域树局部可视化

3.4 智能体 workflow 与运行时状态机

本文系统的目标不是一次性生成一张志愿推荐表，而是在真实数据约束下用尽量少的轮次发现用户隐藏底线。本文业务智能体采用轻量多角色架构，如图 3.6 所示。这里的多角色并不是多个大模型自由协商，而是在同一状态图内部用确定性节点约束角色分工：语义归一层负责从用户输入中抽取分数、选科、专业、地域、预算和风险表达；约束解析器负责区分硬约束与可谈判偏好；确定性证据探针负责从招生数据库、专业树、学费字段、质量画像和地域树返回事实候选；探测规划器负责选择下一轮最应询问的偏好轴；证据谈判器负责把候选对转化为用户可理解的边际替代问题。

系统交互由 LangGraph 式 `interrupt/resume` 机制承载。探索阶段，系统只提出一条高信息增益问题，而不输出冗长推荐列表；用户回答后，图状态恢复并更新后验；当系统认为隐藏底线已足够明确时，才进入利用阶段生成最终解释。这种机制实现了探索与利用的时空隔离：探索期负责降低偏好不确定性，利用期负责给出志愿报告，二者不会混在同一轮回复中造成认知过载。图 3.6 中的暂停与恢复对应 LangGraph 的 `interrupt/resume` 通信；置信上界选轴对应 UCB 主动探测，后验追踪对应 Bradley-Terry 选择模型与 Dempster-Shafer 式犹豫反馈处理。




图 3.6: 交互式偏好澄清工作流程图

3.4.1 LangGraph workflow编排机制

LangGraph 是面向有状态智能体应用的图式编排框架，其核心思想是将一次智能体执行过程表示为由状态、节点和边共同组成的有向图^[34]。状态用于保存图运行期间需要持续传递和更新的数据；节点是具体的计算单元，可以执行模型调用、规则判断、工具访问或外部系统交互；边定义节点之间的控制流，既可以是固定顺序，也可以根据当前状态选择下一跳。与单条链式调用相比，图式编排更适合表达分支、循环、人工介入和多轮会话等复杂控制逻辑。

在工程实现上，LangGraph 通常通过 StateGraph 定义图结构。开发者首先声明状态模式，然后使用 `add_node` 注册节点函数，再通过普通边或条件边连接节点。图的执行从 `START` 进入，并在到达 `END` 时结束；条件边允许路由函数读取当前状态并返回下一节点名称，从而把“如果满足某条件则继续，否则结束或转入另一分支”的控制逻辑显式化。图定义完成后，`compile` 会生成可调用对象，使同一套节点与边能够以同步、异步或流式方式运行。

状态模式是 LangGraph 的记忆管理基础。状态可以由 TypedDict、Pydantic 模型等结构定义，其中每个字段表示一类可跨节点共享的数据。节点返回的字典会被合并回全局状态；对于需要特殊合并语义的字段，LangGraph 支持 `reducer` 机制，例如 `add_messages` 可用于维护对话消息序列。常见消息对象包括 `HumanMessage`、`SystemMessage` 和 `AIMessage`：三者分别表示用户输入、系统级指令和模型或智能体回复。借助结构化状态与消息序列，LangGraph 可以同时保存面向模型的上下文和面向控制流的中间变量。

检查点机制用于支持跨轮会话、故障恢复和人工介入。图在编译时可以挂载 `checkpoint`，并在调用时通过 `thread_id` 标识会话线程；同一个 `thread_id` 对应同一条可恢复的状态轨迹。基于检查点，LangGraph 提供 `interrupt/resume` 人机协作机制：当节点触发中断并向外层交出待处理内容时，图会保存当前状态；外部系统收集人工输入后，再以恢复命令唤醒同一会话。恢复后的反馈会回到原暂停位置，供节点后续逻辑继续使用，使图能够从暂停点继续执行，而无需把整段流程从头重跑。

3.4.2 运行时状态机与通信协议

图 3.7 给出了系统在代码层面的真实流转。入口“对话入口”将用户消息封装为 `HumanMessage`，并以 `thread_id` 作为 `LangGraph` 的检查点会话标识。状态图从“语义归一器”开始，随后进入“约束守门器”；若缺少分数或选科等必要硬约束，则直接返回澄清问题并结束本轮；若约束齐全，则进入“探针规划器”构造探针计划并调用确定性探针。若存在可谈判候选，“证据谈判器”生成一条 A/B 边际替代问题，并借助 `LangGraph` 中断机制暂停本轮图执行，将问题交由外层交互界面呈现给用户。用户下一轮回答到达后，`LangGraph` 用同一个 `thread_id` 恢复状态，“偏好追踪器”解析反馈并更新隐性权重与方差，再回到“探针规划器”继续探索或进入最终报告。




图 3.7: 运行时状态机与 interrupt/resume 通信机制

这一设计使智能体节点间通信具有明确的字段契约。节点之间不传递自由文本长上下文，而是围绕 `AgentState` 中的结构化字段流转。表 3.6 汇总了与本文方法最相关的状态字段。可以看到，系统把显式约束、候选集合、探针计划、最新人类反馈、A/B 特征差和后验参数放在同一个可审计状态对象中，而不是要求大模型在长上下文中自行记忆这些内容。

表 3.6: AgentState 关键字段契约

字段	写入节点	作用
messages	chat_api/report	保存 LangChain 消息序列，支撑最新用户话语读取和最终回复
constraints	gatekeeper	分数、省份、城市、专业、选科、预算、风险偏好等显式约束
baseline_results	gatekeeper	当前硬约束下的基准候选，用作帕累托收益锚点
rewritten_query,	semantic_normalizer	仅归一化显式输入，不输出隐藏画像字段
intent_axes		
probe_plan,	radar	下一轮应调用的确定性探针及候选排序偏好
opportunity_rankings		
pareto_opportunities,	radar	SQL/树结构/画像探针返回的候选集合
candidates		
ucb_target_dimension	radar	UCB 选中的主动学习目标维度
implicit_weights,	preference_tracker	隐性偏好后验均值和不确定性
weight_variance		
latest_agent	negotiator	最近一次 A/B 边际替代问题，用于反馈解析
_probe_question		
latest_human_feedback	interrupt/resume	用户对最近一次探测问题的接受、拒绝或犹豫反馈
latest_pareto_diff	negotiator	$\Phi(B) - \Phi(A)$ ，用于 Bradley-Terry 梯度更新

3.4.3 主动探测的系统级集成

图 3.8 展示了 UCB 机制在系统级工作流中的集成方式。首先，系统根据当前隐性权重均值与方差执行特征维度的置信上限评估，得到 school、major、tuition、quality 和 geo 五个维度的主动学习优先级。随后，探测规划器在最高置信上限维度之间结合显式查询上下文进行语义消歧；例如，当用户表层话语包含专业极端表达时，系统优先检查专业匹配边界，当表达中出现学费或预算约束时，系统优先检查学费底线。接着，系统将抽象偏好维度映射为可审计的数据探针，使主动学习目标落回招生事实表、专业树、学费字段、培养质量画像与地域树。最后，系统通过系统级指令约束保证探测计划必须覆盖当前 UCB 目标，避免语言模型规划器被表层语义或生成惯性带离主动学习策略。

表 3.7 将该调度链路拆解为置信上限评估、上下文消歧、事实探针绑定、系统级指令约束、候选生成、候选对筛选、中断交互和后验吸收八个机制环节。这一链路说明，UCB 并不是一个只写在公式中的抽象策略，而是在规划器前后加入系统级约束：语言模型可以参与探测表达和候选差异解释，但必须服从当前最高信息价值维度；确定性证据层可以返回多个机会集合，但谈判器优先选择能最




图 3.8: UCB 主动探测调度链路

表 3.7: UCB 主动探测的系统级集成机制

机制环节	输入	系统作用
置信上限评估	后验均值与不确定性	计算各偏好维度的主动学习优先级，决定本轮最值得澄清的底线方向
上下文消歧	维度优先级与显式查询	在并列或接近的维度之间利用用户表层语义进行 tie-break，避免随机探测
事实探针绑定	主动学习目标维度	将抽象偏好维度绑定到招生事实、专业树、学费预算、质量画像或地域树等确定性证据层
系统级指令约束	探测计划与 UCB 目标	确保语言模型规划器必须覆盖当前目标维度
候选集生成	显式约束与证据层	返回只包含可审计事实来源的候选集合，避免模型自由生成学校、专业或分数
帕累托散度筛选	候选集合与特征差	选择特征散度最大的 A/B 候选对，并控制重复提问与无收益取舍
中断式交互	边际替代问题与用户回答	在单轮提出一个高信息增益问题，并用真实反馈恢复状态图
后验吸收	反馈标签、目标维度与 $\Delta\Phi$	将接受或拒绝转化为 Bradley-Terry 权重更新，将犹豫反馈转化为不确定性上升

大化 $\|\Delta\Phi\|_1$ 的候选对；用户反馈可以是自然语言，但最终会被解析为接受、拒绝或犹豫，并转化为权重或方差更新。由此，系统把“问什么”从开放式对话策略变成了可复现、可审计的主动学习调度。

3.5 前端界面与交互展示

前端界面承担把复杂系统状态压缩为用户可理解交互的任务。本文不把开发调试入口作为 C 端产品界面，而是将展示层拆分为三类高保真界面：面向考生的偏好澄清界面、面向终局填报的冲稳保报告界面，以及面向研发和评测人员的测试与日志审计后台。三类界面分别对应探索、利用和审计三个阶段，使用户交互、推荐输出和系统可追溯性不混杂在同一个调试面板中。

图 3.9 展示 C 端偏好澄清交互界面。左侧首先折叠展示上一轮预算拒绝记录和 SAVF 预算红线硬截断状态，随后提出处于帕累托边缘的非支配 A/B 反事实探测对：一侧保留学校名气但牺牲计算机核心专业，另一侧保留专业核心度但牺牲学校层次。底部的“倾向方案 A”“倾向方案 B”“难以取舍”分别对应 Bradley-Terry 偏好比较输入和 Dempster-Shafer 式犹豫输入。右侧用灰色虚线和蓝色实线同时展示第 1 轮先验权重与本轮后验权重，使用户可以看到反馈如何改变偏好后验。



图 3.9: C 端偏好澄清交互界面

图 3.10 展示 C 端冲稳保推荐报告页。该界面将多轮澄清得到的偏好后验

转化为终局推荐报告，顶部给出偏好解释摘要，主体按“冲刺梯队”“稳妥梯队”“保底梯队”组织候选长列表。列标题、滚动条和渐隐候选暗示系统在每一档内对更大候选池做全局效用重排；每个候选条目展示学校、专业、预估学费和 $U(x; w_{\text{final}})$ 得分，体现最终排序不是单纯按分数或学校层次，而是对专业契合、地域、预算、学校层次和培养质量进行全局效用重排。

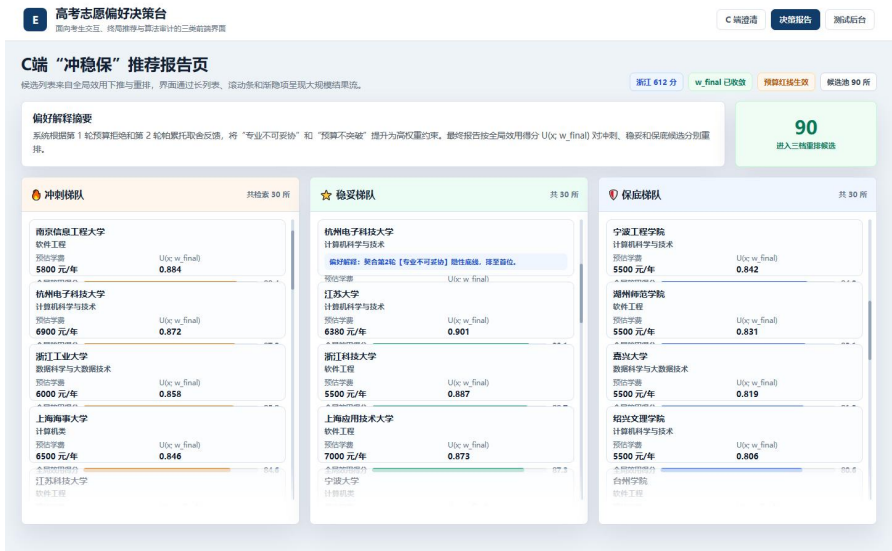


图 3.10: C 端冲稳保推荐报告界面



图 3.11: B 端测试与日志审计后台

图 3.11 展示 B 端受控测试套件与日志审计界面。该界面不面向普通考生，

而是用于研发验收、180 条受控测试画像的自动化回归测试和日志审计：顶部直接展示测试通过数、隐性底线识别 F1 与偏好对齐 MAE；左侧以 CI 列表形式展示测试用例状态；右侧展示单例运行轨迹和原始审计日志。由此，系统既能在 C 端隐藏不必要的工程细节，又能在 B 端保留足够的可追溯证据。

4 系统测试与实验评估

在第3章中，本文详细阐述了高考志愿推荐系统的整体架构与工程实现。该系统通过结构化证据底座、大模型智能体与推荐决策模块的协同，实现了对用户真实偏好的主动探测与在线追踪。然而，高风险决策系统的有效性难以通过传统的“单轮问答准确率”或静态检索命中率来衡量。为科学、定量地检验本系统是否真正达到“从表层话语中发掘隐性底线”的设计预期，本章从系统测试的角度展开评估。本章首先根据第3章的系统架构推导核心测试目标与研究问题；随后，阐述基于“冰山偏好”的显隐分离受控测试集构造方法；最后，通过五模型参考基线横评、系统消融实验和过程指标诊断，评估完整系统在偏好对齐、主动探测和状态追踪上的实际表现。

4.1 测试目标与研究问题

针对第3章设计的各项核心推荐决策模块，本章的系统测试以具体工程模块效能的自动化验收为目标。具体而言，实验围绕以下三个核心研究问题展开：

- (RQ1) **偏好对齐能力（验证后验追踪模块）**：完整系统在经历多轮主动交互后，其偏好追踪器最终推断的五维权重，能否突破用户的语言伪装，有效逼近实验构造的隐藏权重？
- (RQ2) **主动探测有效性（验证主动探测模块）**：引入置信上限（UCB）的主动探测规划器，能否提出最具诊断价值的边际替代问题，从而提高有效探测命中率？
- (RQ3) **状态吸收能力（验证证据谈判与后验追踪闭环）**：系统能否将用户对事实取舍的反馈沉淀为稳定的五维偏好状态，并在终局权重上保持较低误差？

这三个问题分别对应偏好对齐误差、过程探测指标和状态追踪指标。本文同时保留逐轮对话日志，用于解释聚合指标背后的机制差异：去除主动探测模块为什么难以命中有效探测方向，去除后验追踪模块为什么难以沉淀为稳定权重，完整系统又如何通过事实取舍形成可回答的问题。

4.2 面向“冰山偏好”的系统受控测试集设计

4.2.1 显隐分离的沙盒测试机理

高考志愿填报存在典型的“冰山偏好”：考生与家长最初显式表达的诉求（水面之上），往往与内心真正的决策底线（水面之下）存在偏差甚至冲突。为了构造“系统可见信息”与“用户隐藏底线”之间的信息差，本测试集对每一个测试用例进行了严格隔离，将其切分为显性与隐性两部分：

- (1) **显式用户话语（水面之上）**：这是被测系统在首轮唯一可见的自然语言输入，包含分数、选科和一个明确硬约束，例如只看浙江、省外不考虑、只要稳、预算不超过某一金额等。
- (2) **隐藏触发条件与真实权重（水面之下）**：这是对被测系统不可见的部分，仅内置于自动化用户模拟器和评测器中。模拟器根据隐藏触发条件决定是否接受、拒绝或继续追问；评测器利用多维真实权重和候选集合判定系统是否真正发现了有效妥协区域。




图 4.1: 多轮评测流程图

这种“考题与答案物理隔离”的系统级测试沙盒，将答案字段与被测系统运行环境隔离。被测系统的可见信息限定为用户显式话语、后续用户反馈和结构化

数据库证据；隐藏字段、真实权重、可接受候选集合和评测标签仅供模拟器与评测器使用。评测流程如图 4.1 所示。

4.2.2 统一诊断测试集构造

主实验采用统一诊断测试集，共包含 180 条测试画像。该数据集由真实招生数据库重新扫描构造，先依据显式话术和显式条件限定系统首轮可见信息，再从招生事实、学校层次、专业树、分数位次、学费、专业质量画像、就业结果画像和地域树中检索证据探针可达候选，最后通过审计规则保留能够形成真实取舍的问题实例。每条画像同时保存隐藏触发条件、五维真实偏好权重、可接受候选集合和审计示例候选，其中隐藏字段仅供用户模拟器和评测器使用。

为覆盖高考志愿场景中常见的显隐偏好冲突，本文将测试画像归纳为表 4.1 所示的六类诊断轴。表中显式条件定义被测系统看到的表层约束，隐藏触发条件定义模拟器何时接受或拒绝候选，权重映射目的则说明该类画像主要检验的偏好取舍。由此，测试集既能保持候选答案位于系统可达搜索空间，又能为后续推荐集 F1、偏好权重 MAE 和过程探测指标提供统一的评测真值。

表 4.1: 受控测试集设计

诊断轴	显式条件	隐藏触发条件	权重映射目的
地域放宽	只考虑浙江或近邻地区	外省真实可达候选带来学校层次或排名收益	探测地域约束背后的学校收益权衡
专业小类放宽	只读某一专业小类	相近专业换取更高学校层次或质量证据	区分专业匹配与学校质量的相对权重
风险边界放宽	只求稳，不想冲	贴线或轻微冲刺候选有清楚分数证据和收益	检验稳妥偏好是否可被事实收益打破
预算性价比	学费不超过预算上限	小幅超预算但换来层次、排名或质量收益	检验预算底线的边际替代条件
专业质量	强调专业实力证据	同专业或近专业质量评分显著更高	检验质量证据是否能触发专业相关偏好
就业结果	强调就业、薪资或去向	就业结果显著更好且分数可达	检验就业证据对最终选择的驱动作用

上述诊断轴均由结构化证据层支撑。图 4.2 展示了数据证据与放宽动作之间的关系：招生事实负责候选可达性检查，专业树支撑专业放宽，分数与位次支撑风险边界，学费字段支撑预算性价比，专业质量和就业结果画像支撑质量、就业导向筛选，地域树支撑分阶段地域放宽。




表 4.2: 确定性探针函数、证据来源与放宽动作

探针函数	主要证据来源	产生的可谈判动作
run_baseline	admission_scores, schools, admission_plans, subject_requirements, admission_scores, schools	在显式硬约束内返回基准候选，用作后续收益比较锚点
probe_major_geo_relax	major_tree_final_reviewed.json, school_tier/ranking, admission_scores.min_score	分阶段放宽专业或地域约束，寻找学校层次、排名或专业相关收益
probe_risk_band_relax	admission_scores.min_rank, score_rank_segments	将单一保守偏好扩展为可解释的贴线或轻微冲刺候选
probe_tuition_value_relax	admission_plans.tuition, schools.ranking, baseline_results	在预算窗口附近寻找有层次或质量收益的候选
probe_major_quality_relax	school_major_quality_profiles, baseline_results, major_employment	保持或分阶段放宽专业，寻找质量分更高的候选
probe_employment_outcome_relax	_outcome_profiles, major_tree_final_reviewed.json, region_geo_tree_reviewed_v1.json	用就业排名、行业、岗位和薪资证据引出就业导向偏好
probe_region_tree_relax	region_urban_tier_tree_reviewed_v1.json, admission_scores	将“别太远”“好城市”等表达转为经审校的地域替代问题

表 4.2 进一步说明，探针函数承担数据证据到放宽动作的固定接口功能。规划器可以决定优先调用哪个探针，谈判器可以决定如何表达候选差异，学校、专业、分数、位次、学费、质量分、就业分和地域节点均来自这些探针的返回值。

4.3 实验配置与系统变体构建

实验分为参考基线横评和内部消融两层。参考基线横评用于回答“更换强模型和提示技巧是否足以替代多轮偏好启发”；内部消融用于剥离主动探测和后验追踪两个模块的机制贡献。用户模拟器和裁判均固定使用同一轻量模型 DeepSeek-V4-Flash，以控制被测模型切换带来的模拟器漂移；被测模型随实验设置变化。

1. 参考基线横评

参考基线横评在同一测试画像集合上运行五个模型：智谱 GLM-5.1、深度求索 V3.2、MiniMax M2.5、月之暗面 Kimi-K2.6 和通义千问 Qwen3.6。每个模型分别运行三种方法：

- (1) **完整系统**：沿用第 3 章的证据探针、帕累托谈判和后验更新链路。
- (2) **静态检索-直接提示**：先运行静态候选召回和冲稳保分段，再由模型直接组织推荐文本。
- (3) **静态检索-思维链提示**：使用同一静态候选召回结果，但提示模型显式组织推理过程后再给出推荐。

三种方法的可见输入均限定为显式话语、对话反馈和检索候选。静态检索方法使用同样的显式话语和检索候选，检验“一次性检索加更强表达”能否替代多轮证据谈判。

2. 系统内部消融组

内部消融固定使用智谱 GLM-5.1 作为被测模型，以区分模型能力差异与模块机制贡献。三类系统变体如下：

- (1) **完整系统**：启用 UCB 主动探测规划、帕累托候选构造、Bradley-Terry 后验追踪和 Dempster-Shafer 犹豫反馈处理。

(2) **去除主动探测**: 关闭 UCB 维度调度, 探测维度退化为非目标化策略, 用于测试主动规划对偏好覆盖和张力构造的贡献。

(3) **去除后验追踪**: 关闭权重更新机制, 系统可以继续提问和表达候选, 但五维偏好状态保持冻结, 用于测试长期状态追踪对最终偏好对齐的贡献。

上述设置形成了显式话语与隐藏评测边界并存的受控比较环境, 使参考基线、完整系统与消融系统面对相同用户话语、相同结构化证据来源和相同隐藏评测边界。本文围绕 180 条受控测试画像组织自动化运行; 每条运行日志记录最终五维权重、逐步方差、被选探测维度、结构化候选列表和候选对特征差异, 用于终局指标和过程指标的离线计算。

实验数据集中的隐藏触发条件、真实权重和可接受候选集合仅供模拟器与评测器使用。被测系统只能根据显式话语、对话反馈和结构化数据库证据推断偏好状态。用户模拟器按照隐藏触发条件给出接受、拒绝或追问反馈, 不能主动说出隐藏候选; 若候选信息首先由用户模拟器泄露, 或系统复读用户泄露信息, 则该候选不作为有效推荐证据。该隔离规则贯穿后续 F1、MAE 和过程指标的判读, 保证指标反映系统自身的主动探测和状态追踪能力。

4.4 参考基线横评结果

参考基线横评首先关注不同基座模型和提示方式在同一候选池中的排序能力。测试画像集合同时维护共享可达候选池 $\mathcal{C}$, 该候选池由显式条件内的基准候选、系统证据探针返回的结构化候选、可接受候选集合和审计示例候选合并去重得到。每个候选 $c \in \mathcal{C}$ 都被映射为五维结构化特征向量 $\phi(c)$, 包括学校层次、专业匹配、学费、质量证据和地域匹配。令隐藏真实权重为 $\mathbf{w}^*$, 系统最终推断权重为 $\hat{\mathbf{w}}$, 则真实排序分数和系统排序分数分别为

$$s^*(c) = \mathbf{w}^* \cdot \phi(c), \quad \hat{s}(c) = \hat{\mathbf{w}} \cdot \phi(c). \quad (4-1)$$

推荐集 $F1@N$ 用于衡量最终偏好状态能否把真实高效用候选排到前列。令 G_N 为按 s^* 排序得到的真实 Top- N 候选集合, P_N 为按 $\hat{s}$ 排序得到的系统 Top- N 候选集合, 则

$$P@N = \frac{|P_N \cap G_N|}{|P_N|}, \quad (4-2)$$

$$R@N = \frac{|P_N \cap G_N|}{|G_N|}, \quad (4-3)$$

$$F1@N = \frac{2P@NR@N}{P@N + R@N}. \quad (4-4)$$

本文在参考基线横评中报告 F1@1、F1@3 和 F1@5。F1@1 检验首位推荐是否命中真实最优候选，F1@3 反映头部强推荐的精确程度，F1@5 对应志愿推荐中常见的短列表比较场景。

表 4.3: 参考基线横评结果表

方法	基座模型	样本数	F1@1	F1@3	F1@5
完整系统	智谱 GLM-5.1	180	0.743	0.633	0.680
	深度求索 V3.2	180	0.727	0.644	0.687
	MiniMax M2.5	180	0.738	0.644	0.707
	月之暗面 Kimi-K2.6	180	0.738	0.633	0.687
	通义千问 Qwen3.6	180	0.721	0.644	0.707
静态检索-直接提示	智谱 GLM-5.1	180	0.700	0.600	0.673
	深度求索 V3.2	180	0.700	0.600	0.673
	MiniMax M2.5	180	0.700	0.600	0.673
	月之暗面 Kimi-K2.6	180	0.700	0.600	0.673
	通义千问 Qwen3.6	180	0.700	0.600	0.673
静态检索-思维链提示	智谱 GLM-5.1	180	0.700	0.600	0.673
	深度求索 V3.2	180	0.700	0.600	0.673
	MiniMax M2.5	180	0.667	0.600	0.667
	月之暗面 Kimi-K2.6	180	0.700	0.600	0.673
	通义千问 Qwen3.6	180	0.700	0.589	0.667

表 4.3 按方法和基座模型列出参考基线横评结果。整体趋势显示，完整系统相对两类静态检索提示主要提升首位推荐和短列表排序质量。这说明系统增

益并非来自简单扩大可召回候选集合，而是来自对候选优先级的重新校准：静态检索只能依据初始显式话语估计偏好，面对“地域可放宽但学校层次不可退让”“专业方向可近邻替代但质量证据必须充分”等隐藏底线时，容易把表层条件相似的候选排在前面；完整系统通过 UCB 主动选择不确定且有诊断价值的维度，再由帕累托谈判把学校、专业、费用、质量和地域之间的取舍显式化，最后用 Bradley-Terry 后验追踪把接受、拒绝和犹豫反馈写入权重状态，因此更容易把真实高效用候选提前到头部位置。该趋势在不同基座模型上保持一致，表明系统效果主要来自交互式证据链路本身，而不是依赖某一个模型的单轮生成能力。

图 4.3 进一步显示，完整系统的优势集中在首位推荐和短列表排序上。这一变化符合志愿推荐场景的实际需求：用户真正依赖的是最先看到、最需要比较的一小组候选。因此，完整系统在头部指标上的提升更能体现其价值，即把隐藏偏好对应的机会从“列表中存在”推进到“优先被推荐”。




图 4.3: 参考基线横评结果图

4.5 主消融实验结果

主消融实验在固定基座模型下考察主动探测和后验追踪两个模块对偏好状态本身的贡献，因此在 F1 之外引入平均绝对误差（MAE）。设偏好维度集合为 $\mathcal{D} = \{\text{school, major, tuition, quality, geo}\}$ ，系统最终推断权重为 $\hat{\mathbf{w}}$ ，隐藏真实权重为 $\mathbf{w}^*$ ，则

$$\text{MAE}(\hat{\mathbf{w}}, \mathbf{w}^*) = \frac{1}{|\mathcal{D}|} \sum_{k \in \mathcal{D}} |\hat{w}_k - w_k^*|. \quad (4-5)$$

MAE 越低，说明多维偏好状态越接近测试集构造的真实权重；与上一节的推荐集 F1 结合，可以同时观察“状态是否学准”和“候选是否排准”。因此，本节以 MAE 作为消融判断的主线，并用 F1@1、F1@3 和 F1@5 辅助解释头部排序变化。

表 4.4 汇总主消融实验结果。消融趋势表明，完整系统在偏好对齐误差和头部推荐上保持整体优势；去除主动探测后，MAE 明显上升，F1@3 与 F1@5 同步退化，说明没有 UCB 调度时，后续追问更容易停留在显式条件或低区分度维度上，Bradley-Terry 更新即使仍然存在，也只能吸收诊断价值不足的反馈。去除后验追踪后，状态更新链路被冻结，首位推荐和短列表 F1 均低于完整系统，说明仅有提问和候选表达不足以改善最终排序，用户对候选取舍的反馈必须写入可延续的五维权重。

表 4.4: 主消融实验结果

基座模型	系统	样本数	MAE	F1@1	F1@3	F1@5
智谱 GLM-5.1	完整系统	180	0.144 ± 0.045	0.767 ± 0.430	0.667 ± 0.371	0.700 ± 0.277
智谱 GLM-5.1	去除主动探测	180	0.178 ± 0.035	0.733 ± 0.450	0.611 ± 0.329	0.680 ± 0.276
智谱 GLM-5.1	去除后验追踪	180	0.149 ± 0.016	0.700 ± 0.466	0.600 ± 0.344	0.673 ± 0.285




图 4.4: 主消融实验核心指标（智谱 GLM-5.1）

图 4.4 与表格结论一致：完整系统同时压低偏好状态误差并改善头部推荐，

说明主动探测、帕累托谈判和后验追踪之间形成了闭环。UCB 负责找到值得询问的偏好方向，帕累托候选负责把该方向转化为有真实成本感的选择，后验追踪负责把选择结果转化为下一轮排序所使用的权重，Dempster-Shafer 犹豫处理则为不确定反馈提供保守吸收机制。任一环节被移除后，系统都无法稳定完成“发现隐藏底线-形成权衡问题-写入偏好状态-提前推荐有效候选”的链路，这正是完整系统相对静态检索和消融系统体现效果的关键。

4.6 交互微观动力学与状态演化诊断

多轮偏好澄清同时体现在探测侧和追踪侧两个层面。探测侧回答“系统是否问到有效区域，以及问题是否具有真实取舍感”；追踪侧回答“用户回答后，反馈是否进入可延续的偏好状态，并最终改善推荐排序”。对话推荐系统评估研究已经指出，单纯依赖终局推荐质量会掩盖偏好启发过程本身的差异^[27,41]；交互式偏好查询与多目标优化研究也强调，用户反馈的价值取决于系统提出的问题是是否具有足够的成本感知和权衡张力^[42-43]。因此，本节不把过程指标作为新的分数排行榜，而是用它们解释完整系统为什么能够把隐藏底线转化为可更新的偏好状态。

过程诊断共包含五类指标：

- (1) **偏好覆盖梯度**：记录每轮探测方向是否落入画像给定的可接受探测维度和探针键集合，并报告有效探测命中率和累计覆盖率，用来衡量主动探测规划器是否把问题推向有诊断价值的区域。
- (2) **全局认知不确定性衰减率**：记第 t 轮五维后验方差之和为 $V_t = \sum_{k \in \mathcal{D}} v_{t,k}$ ，使用 $(V_0 - V_T)/(T - 1)$ 表示交互过程中不确定性的平均下降速度。该指标只在系统存在有效权重或方差更新轨迹时参与比较。
- (3) **边际替代张力指数**：对谈判器提出的候选对 (A_t, B_t) 计算结构化特征差异的 L_1 范数，即 $\|\phi(B_t) - \phi(A_t)\|_1$ ；当某轮采用单候选探针时，使用该画像候选集的审计张力作为补充。
- (4) **明确权衡触发率**：统计系统提问后，用户回复中出现明确接受或拒绝反馈的比例，用来观察候选取舍问题是否足够具体。

(5) **信念震荡指数**：衡量多轮权重轨迹的折返程度，定义为

$$\text{信念震荡指数} = \frac{\sum_t \|\mathbf{w}_t - \mathbf{w}_{t-1}\|_2}{\|\mathbf{w}_T - \mathbf{w}_0\|_2}. \quad (4-6)$$

信念震荡指数接近 1 表示权重更新路径较接近单调移动，数值越大表示中间折返越明显。

除上述派生指标外，本文还记录状态更新次数，用于直接观察后验追踪器是否把用户反馈写入可延续状态。对于去除后验追踪系统，权重状态被冻结，全局认知不确定性衰减率和信念震荡指数标记为状态冻结项；冻结为 0 表示没有状态轨迹，不参与“越低越好”或“越高越好”的排序解释。下文将偏好覆盖梯度、全局认知不确定性衰减率、边际替代张力指数和明确权衡触发率归入主动探测链路，将状态更新次数、平均绝对误差、推荐集头部命中指标和信念震荡指数归入后验追踪链路展开分析。

4.6.1 主动探测的有效性：从探测方向到权衡问题

图 4.5 展示主动探测相关过程指标。完整系统相对去除主动探测系统，在有效探测命中率和覆盖率上均明显上升；去除后验追踪系统仍保持较高的探测命中，说明这一提升主要来自主动探测规划器，而不是后验权重更新本身。其机制在于，主动探测规划器将当前偏好方差和候选证据的不确定性同时纳入选择，使系统优先询问“可能改变排序、且能触发隐藏底线”的维度。若移除该规划器，对话仍可能继续追问，但追问方向更容易被初始显式条件牵引，例如反复确认地域、分数或专业大类，而不是进入真正有诊断价值的学校层次、质量证据或费用取舍。因此，偏好覆盖梯度的上升说明完整系统并非只是多问几轮，而是把有限交互轮次投入到了更有效的偏好空间。

全局认知不确定性衰减率的变化幅度小于偏好覆盖梯度，但方向仍与主动探测一致：完整系统的不确定性衰减更快，去除主动探测后衰减变慢。这个现象说明，非目标化追问有时也能得到可更新反馈，所以方差并不会完全停滞；但由于问题没有稳定命中隐藏底线所在维度，反馈对真实排序的贡献不稳定，最终仍会反映为平均绝对误差和头部推荐指标的下降。去除后验追踪系统没有可用的方差更新轨迹，全局认知不确定性衰减率只能标记为状态冻结项，这也从侧面说明“不确定性衰减”必须依赖可更新的后验状态才有解释意义。




图 4.5: 主动探测链路的方向命中与不确定性衰减指标

4.6.2 主动探测的问题质量诊断

探测命中有效方向后，系统还需要把候选差异组织成用户能够明确回答的问题。图 4.6 显示，完整系统和去除后验追踪系统都能维持较高的边际替代张力，而去除主动探测后该指标显著下降；明确权衡触发率也呈现同向变化。其原因是帕累托谈判器只有在上游给出清晰探测方向时，才能构造“多得到什么、同时要放弃什么”的候选对。例如学校层次提升往往伴随地域放宽，专业质量提升可能伴随费用或风险变化，这类结构化差异为用户表达真实取舍提供了清楚语境。若缺少主动探测调度，候选对更可能停留在表层相似项之间，用户即使回答，也难以形成明确的接受或拒绝反馈。




图 4.6: 主动探测形成的权衡问题质量指标

去除后验追踪系统在问题张力上接近完整系统，但终局排序仍不如完整系统，说明“问得好”和“学得进”是两个不同环节。主动探测链路负责把问题变成有成本感的比较，后验追踪器负责把用户对比较题的选择写入权重状态。该结果把系统效果拆解得更清楚：完整系统的优势不是单纯来自更自然的提问，而是来自高张力问题与可更新状态之间的闭环。

4.6.3 后验追踪的状态吸收诊断

图 4.7 展示后验追踪相关指标。去除后验追踪后，状态更新次数归零，平均绝对误差上升，短列表推荐指标下降；完整系统则同时保持较低的偏好误差和更好的头部排序。这说明后验追踪器的价值不在于额外生成候选，而在于把用户的接受、拒绝和犹豫反馈吸收到五维权重中，使下一轮排序函数真正发生变化。结合表 4.4 可见，去除主动探测系统虽然仍有状态更新，平均绝对误差和头部推荐指标仍然退化，这进一步说明状态更新的数量不是关键，反馈是否来自正确诊断维度才是关键。




图 4.7: 后验追踪器过程指标

后验追踪是否有效，应优先观察平均绝对误差、头部推荐指标和状态轨迹。信念震荡指数提供了另一层解释：完整系统的权重轨迹存在真实移动，但整体接近单调吸收；去除主动探测后，反馈来源更分散，权重更容易发生折返。换言之，完整系统不是把权重“锁死”在初始判断上，而是在有诊断价值的反馈到来时移动，并尽量避免由低质量追问引起的摇摆。

综上，过程诊断支持两条机制链路的分工：主动探测负责“问哪里、问题是否有真实取舍”，后验追踪负责“回答是否进入可延续状态”。完整系统同时改善探测方向、问题张力和状态吸收；去除主动探测后，反馈来源更分散并导致权重轨迹更易折返；去除后验追踪后，状态更新归零，终局排序只能停留在未吸收反馈的候选表达上。因此，这些过程指标共同说明，系统有效性来自“有效探测方向—高张力取舍问题—可延续偏好状态”的闭环。

5 总结与展望

5.1 全文工作总结

本文围绕大模型驱动的高考志愿推荐系统设计与实现展开研究，并将高考志愿填报中的隐藏偏好发现作为系统核心问题。与传统检索增强生成系统不同，本文系统不把用户第一轮显式表达视为完整偏好函数，而是将志愿咨询建模为事实约束下的多轮偏好澄清过程。系统先用确定性数据库探针生成事实可达候选，再通过非补偿性单属性价值函数映射候选特征，用 UCB 主动选择最有诊断价值的偏好维度，并基于 Bradley-Terry 选择模型和 Dempster-Shafer 式犹豫处理维护在线后验。

本文的核心问题不是“能否生成一段表面合理的志愿建议”，而是“能否把招生事实、用户约束、主动澄清和推荐解释组织为一个可运行、可复查的系统”。围绕这一目标，本文以传统混合检索基线为对照，进一步实现证据驱动的偏好建模与交互决策链路：前者验证了高考志愿咨询可以被组织为带状态、检索和重排的智能体增强 RAG 流程，后者则进一步把软约束召回推进为系统化的偏好澄清过程。

5.2 主要贡献

第一，本文提出冰山式偏好问题定义，指出高风险决策中的用户话语常具有防御性和不完整性。系统若只执行显式约束，就会陷入偏好幻觉；若只做线性加权排序，就会陷入线性补偿陷阱。

第二，本文构建了面向志愿推荐的数据证据层，将招生事实表、专业树、学费字段、培养质量画像和地域树组织为可审计的证据底座，使学校、专业、分数、位次和学费等事实字段不再由大模型自由生成。

第三，本文实现了推荐决策模块，将非补偿性 SAVF、UCB 主动澄清、Bradley-Terry 在线后验追踪和 D-S 式犹豫处理结合起来，使系统能够在结构化事实约束下识别用户真实底线并更新偏好状态。

第四，本文实现了运行时状态机，将语义归一、约束解析、证据探针、澄清问题、用户反馈和最终推荐组织为可回放的工程链路，增强了系统可审计性。

第五，本文构建系统受控测试集，将带隐藏底线的用户画像、自动对弈日志和定量指标结合起来，使隐藏偏好澄清从案例叙述变为可复查的系统测试。

5.3 实验结论

系统受控测试集的结果整体支持本文设计。第4章的参考基线对比显示，静态检索方法在五个基座模型上的结果趋势一致，说明一次性静态检索难以自然恢复用户真实底线，单纯的模型能力提升并不能解决这一问题，完整系统的优势主要来自交互过程中对候选优先级的重新校准。主消融实验进一步表明，主动探测主要贡献于探测方向选择，后验追踪主要贡献于反馈吸收与状态稳定。因此，完整系统的优势并不是来自大语言模型对初始查询的零样本猜测，而是来自“事实证据构造边际替代问题-用户反馈-BT/D-S 后验更新”的机制。

5.4 局限性

本文仍存在局限。第一，系统受控测试集使用模拟用户，适合验证机制差异，但尚不能替代真实用户研究。真实考生和家长的表达可能更含混、情绪更强，也可能受到家庭成员意见变化的影响。第二，本文当前证据层主要围绕浙江高考数据构建，跨省份和跨年份泛化仍需额外验证。第三，系统主动提问具有一定引导性，虽然有助于快速发现底线，但真实产品中仍需要控制语气、解释权和退出机制，避免用户感到被系统强行引导。第四，本文主要处理学校层次、专业、学费、培养质量和地域五类维度，真实志愿决策还包含城市生活成本、家庭照护距离、专业转出政策、保研机会等更复杂因素。

5.5 后续工作

后续工作可以从三方面展开。第一，将系统受控测试集扩展到真实用户研究，比较模拟器反馈与真实考生反馈的一致性。第二，扩展证据层和价值函数，使就业、城市机会、专业转出难度和长期发展路径能够进入更细粒度的非补偿性建模。第三，在交互设计上引入更温和的用户控制机制，例如允许用户标记“暂不讨论该底线”、调整系统主动性强度，或查看后验权重变化解释。

6 参考文献

- [1] ZHANG X, LI C, ZONG Y, et al. Evaluating the Performance of Large Language Models on GAOKAO Benchmark. 2024. <https://arxiv.org/abs/2305.12474>. arXiv: 2305.12474.
- [2] LIN S, HILTON J, EVANS O. TruthfulQA: Measuring How Models Mimic Human Falsehoods. *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2022: 3214-3252. <https://aclanthology.org/2022.acl-long.229/>.
- [3] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. 2020. arXiv: 2005.11401.
- [4] CHENG M, LUO Y, OUYANG J, et al. A Survey on Knowledge-Oriented Retrieval-Augmented Generation. 2025. <https://arxiv.org/abs/2503.10677>. arXiv: 2503.10677.
- [5] LI Z, WANG Z, WANG W, et al. Retrieval-augmented generation for educational application: A systematic survey. *Computers and Education: Artificial Intelligence*, 2025: 100417.
- [6] XU X, ZHANG C, LU Y, et al. LLM and Generative AI for Education: A Survey. 2024. <https://arxiv.org/abs/2405.13001>. arXiv: 2405.13001.
- [7] WANG S, XU T, LI H, et al. Large language models for education: A survey and outlook. *arXiv preprint arXiv:2403.18105*, 2024. <https://arxiv.org/abs/2403.18105>.
- [8] YAN L, SHA L, ZHAO L, et al. Practical and ethical challenges of large language models in education: A systematic scoping review. *British Journal of Educational Technology*, 2024, 55(1): 90-112.
- [9] HUANG Y, BAI Y, ZHU Z, et al. C-Eval: A Multi-Level Multi-Discipline Chinese Evaluation Suite for Foundation Models. *Advances in Neural Information Processing Systems*: vol. 36. 2023. <https://arxiv.org/abs/2305.08322>.
- [10] LI H, ZHANG Y, ZHANG F K, et al. CMMLU: Measuring Massive Multitask Language Understanding in Chinese. 2023. <https://arxiv.org/abs/2306.09212>. arXiv: 2306.09212.
- [11] OZMEN B B, MATHUR P. Evidence-based artificial intelligence: Implementing retrieval-augmented generation models to enhance clinical decision support in plastic surgery. *Journal of Plastic, Reconstructive & Aesthetic Surgery*, 2025, 104: 414-416.
- [12] AZIE S, MENG Y. The Ethical Compass of the Machine: Evaluating Large Language Models for Decision Support in Construction Project Management. *arXiv preprint arXiv:2509.04505*, 2025.
- [13] GAO Y, XIONG Y, GAO X, et al. Retrieval-Augmented Generation for Large Language Models: A Survey. 2023. <https://arxiv.org/abs/2312.10997>. arXiv: 2312.10997.
- [14] ASAI A, WU Z, WANG Y, et al. Self-rag: Learning to retrieve, generate, and critique through self-reflection. *The Twelfth International Conference on Learning Representations*. 2023.
- [15] YAN S Q, GU J C, ZHU Y, et al. Corrective retrieval augmented generation. 2024.
- [16] JEONG S, BAEK J, CHO S, et al. Adaptive-rag: Learning to adapt retrieval-augmented large language models through question complexity. *arXiv preprint arXiv:2403.14403*, 2024.
- [17] EDGE D, TRINH H, CHENG N, et al. From Local to Global: A Graph RAG Approach to Query-Focused Summarization. 2024. <https://arxiv.org/abs/2404.16130>. arXiv: 2404.16130.
- [18] SARTHI P, ABDULLAH S, TULI A, et al. RAPTOR: Recursive Abstractive Processing for Tree-Organized Retrieval. *The Twelfth International Conference on Learning Representations*. 2024. <https://openreview.net/forum?id=GN921JHCRw>.
- [19] LI Z, CHEN X, YU H, et al. Structrag: Boosting knowledge intensive reasoning of llms via inference-time hybrid information structurization. *arXiv preprint arXiv:2410.08815*, 2024.
- [20] SINGH A, EHTESHAM A, KUMAR S, et al. Agentic retrieval-augmented generation: A survey on agentic rag. *arXiv preprint arXiv:2501.09136*, 2025.
- [21] GAO F, XU S, HAO W, et al. KA-RAG: Integrating Knowledge Graphs and Agentic Retrieval-Augmented Generation for an Intelligent Educational Question-Answering Model. *Applied Sciences*, 2025, 15(23): 12547.

- [22] NGUYEN-DUC A, MANH C V, TRAN B A, et al. An Empirical Study of Multi-Agent RAG for Real-World University Admissions Counseling. 2025. <https://arxiv.org/abs/2507.11272>. arXiv: 2507.11272.
- [23] ZHOU X, HE J, ZHOU W, et al. A Survey of LLM $\times$ DATA. 2025. <https://arxiv.org/abs/2505.18458>. arXiv: 2505.18458.
- [24] JANNACH D, MANZOOR A, CAI W, et al. A Survey on Conversational Recommender Systems. *ACM Computing Surveys*, 2021, 54(5): 1-36.
- [25] GAO C, LEI W, HE X, et al. Advances and Challenges in Conversational Recommender Systems: A Survey. *AI Open*, 2021, 2: 100-126.
- [26] CHRISTAKOPOULOU K, RADLINSKI F, HOFMANN K. Towards Conversational Recommender Systems. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016: 815-824.
- [27] JANNACH D, MANZOOR A, CAI W, et al. Evaluating Conversational Recommender Systems: A Landscape of Research. *Artificial Intelligence Review*, 2023, 56: 2365-2401.
- [28] LI L, CHU W, LANGFORD J, et al. A Contextual-Bandit Approach to Personalized News Article Recommendation. *Proceedings of the 19th International Conference on World Wide Web*. ACM, 2010: 661-670.
- [29] AUER P, CESA-BIANCHI N, FISCHER P. Finite-time Analysis of the Multiarmed Bandit Problem. *Machine Learning*, 2002, 47(2): 235-256.
- [30] BRADLEY R A, TERRY M E. Rank Analysis of Incomplete Block Designs: I. The Method of Paired Comparisons. *Biometrika*, 1952, 39(3/4): 324-345.
- [31] DEB K, PRATAP A, AGARWAL S, et al. A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE Transactions on Evolutionary Computation*, 2002, 6(2): 182-197.
- [32] NIU C, WANG X, CHENG X, et al. Enhancing dialogue state tracking models through LLM-backed user-agents simulation. *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. 2024: 8724-8741.
- [33] WU Y, YUE T, ZHANG S, et al. Stateflow: Enhancing llm task-solving through state-driven workflows. *arXiv preprint arXiv:2403.11322*, 2024.
- [34] AI L. LangGraph Documentation. 2024. <https://langchain-ai.github.io/langgraph/>.
- [35] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models. *Advances in neural information processing systems*, 2022, 35: 24824-24837.
- [36] MULTI-GRANULARITY M L M F. M3-Embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. *arXiv preprint arXiv:2402.03216*, 2024.
- [37] ZHANG Y, LI M, LONG D, et al. Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models. *arXiv preprint arXiv:2506.05176*, 2025. <https://arxiv.org/abs/2506.05176>.
- [38] KWON W, LI Z, ZHUANG S, et al. Efficient memory management for large language model serving with pagedattention. *Proceedings of the 29th symposium on operating systems principles*. 2023: 611-626.
- [39] CORMACK G V, CLARKE C L A, BUETTCHE S. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*. ACM, 2009: 758-759.
- [40] SARMAH B, MEHTA D, HALL B, et al. Hybridrag: Integrating knowledge graphs and vector retrieval augmented generation for efficient information extraction. *Proceedings of the 5th ACM International Conference on AI in Finance*. 2024: 608-616.
- [41] KIM S, SEO K, KIM T, et al. Stop Playing the Guessing Game! Evaluating Conversational Recommender Systems via Target-free User Simulation. *Findings of the Association for Computational Linguistics: EMNLP 2025*. Suzhou, China: Association for Computational

- Linguistics, 2025: 19588-19605. <https://aclanthology.org/2025.findings-emnlp.1067/>.
- [42] BURNAT F A D. QUIVER: Cost-Aware Adaptive Preference Querying in Surrogate-Assisted Evolutionary Multi-Objective Optimization. 2026. <https://arxiv.org/abs/2605.04267>. arXiv: 2605.04267.
- [43] KEENEY R L, RAIFFA H. Decisions with Multiple Objectives: Preferences and Value Trade-offs. Cambridge: Cambridge University Press, 1993.

作者简历

基本信息：

姓名：潘臻琦 性别：男 民族：汉 出生年月：2003.2 籍贯：江西省萍乡市

教育经历：

- 2021.9 – 2026.6 浙江大学计算机科学与技术学院，计算机科学与技术专业，攻读学士学位。